oGMemory 多模态记忆技术评估
M3-Bench 五视频实验

memory-eval 工作区实验记录

2026 年 10 月 31 日

摘要

本报告对 oGMemory dev 分支的多模态记忆与问答流程进行代码审计，并在 M3-Bench robot 子集固定抽取五个完整视频、共 65 题开展实际实验。评估同时关注媒体覆盖、记忆生成、检索与问答、自动评分及执行可靠性。原始默认配置、环境修复和后续恢复严格区分；不以历史答案代替本次运行，不以缺题后的成功子集均分代替端到端表现。当前结果属于小规模开发性诊断，不是完整数据集成绩，也不是独立人工验证的准确率。本报告保留首轮失败、定向恢复和共同重评三个阶段；最终同模型对照以第 8 节为准，不将不同阶段的较高分数择优拼接。

1 目标与可追溯性

主要评估对象是当前目录的 `oGMemory/`，未开展新的 LoCoMo 实验。源码分支为 dev，固定提交为 `8c86c3ed`（完整哈希见实验目录 `provenance.json`）。本轮不修改记忆与检索算法，为 M3 配置工厂和 MiniMax 适配器补充可选推理参数透传，并加入默认关闭、最多 4 个独立片段并发的吞吐优化；固定提交加补丁构成实际运行版本。新增脚本、脱敏配置、逐题结果和报告均置于外层 memory-eval 工作区。模型、数据库、配置与抽样清单分别记录，凭据和大型原始媒体不纳入拟建立的 Git 仓库。

2 当前方法

2.1 输入与多模态证据

完整管线定义于 `config/m3/pipelines/video_episodic_full.yaml`，包括 18 个阶段。视频按 30 秒切片，建立 VIDEO RawNode；画面与音频作为带来源关系的子节点。音频为 16 kHz 单声道，Whisper large-v3-turbo 产生带时间标记的英语转写；pyannote 分离说话人，SpeechBrain ECAPA 产生声纹特征，HTTP CV 服务处理人脸。

画面按 1 fps 取至多 16 帧，缩放参数为 512，JPEG 质量参数为 80。**默认帧主要来自片段前约 0–15 秒，而非覆盖全片段的均匀采样**。因而“完整视频实验”只表示处理全部片段与完整音频，不能解释为视觉观察无遗漏。

2.2 情景记忆与图组织

`m3/episodic_memory.py` 将画面、可用原始音频和 ASR 转写交给多模态情景记忆算子，生成

description、characters、events、entities，并存为片段对应的 ExtractedNode。后续创建具有支持来源的 MemoryNode；人脸与声音聚类产生身份关联，语义整合阶段生成视频级聚合 MemoryNode。

视频级整合是确定性的描述拼接与集合去重，描述上限为 50,000 UTF-8 字节，并同步 SUPPORTS / EVOLVES 关系；不是新的大模型抽象推理过程，也不自动保证事实冲突消解、事件去重计数或长期状态一致性。被截断的多模态输出明确记为失败，不能通过补齐 JSON 括号冒充有效记忆。

2.3 索引、检索与回答

结构化记忆和原始 ASR 转写展开为文本，使用 BGE-M3 1024 维嵌入，写入 SQL 图及向量索引。默认 Search 检索 `episodic_memory_generator` 类型的 ExtractedNode：原始查询向量召回，必要时追加去人名查询，结合转写 BM25 重排及独立 transcript 词法召回，经 RRF 融合后补充邻近片段和时间边界转写。

生成身份图和语义汇总不等于默认问答直接检索了这些图结构。本次不能据管线执行完整就宣称图关系或视频级语义汇总提高了答案质量；这需要独立消融与实际证据路径审计。

ReAct 问答通过 Search / Answer 工具运行，最多 6 轮，循环预算 180 秒。默认主检索 top-k=8，向量候选 20，转写候选 20，邻居半径 1，邻居上下文最多 8 条。未启用可选 `m3.qa_context`：默认 top-k 不是模型不可突破的服务端上限，不同查询的重叠内容仍可能累积。单次请求 timeout=300 秒与 SDK 重试也意味着 180 秒不是端到端硬时限。

2.4 时间与权限边界

检索限制在当前账号和视频范围。问题 timestamp 优先于原始 before_clip 编号，并根据实际片段来源区间定位。本次采用 `current_clip`，证据截止时间扩展到问题所在片段末尾，可能包含问题之后的少量内容。因此该协议**不是严格因果在线问答**；实际宽限由每题 `temporal_scope` 记录。后续严格时间策略应单独对比。

3 与 M3-Agent 的实现差异及对照评测设计

3.1 范围与实现路径

本节依据本地 `m3-agent/` 的固定提交 `0e3e419` 做静态代码审计，不是新增 M3-Agent 跑分。其 robot 标注与本次数据副本的规范化 JSON 哈希一致，五视频 65 题逐项匹配；记录见 `docs/m3_agent_review.json`。本次未加载参考模型权重、未反序列化 pickle 图、未调用参考模型 API，也未运行可能改变现有 GPU 环境的参考安装脚本。

参考实现分为感知中间产物、记忆图生成和控制问答三个入口。每个视频维护一个 `VideoGraph`，包含 img（人脸）、voice、episodic 和 semantic 节点及双向加权边，最后保存为 pickle。感知侧使用 InsightFace，以及代码中声明的 Gemini 对话分段和 ERes2NetV2 声纹。这不同于本轮 Whisper、pyannote、ECAPA 的组合。

记忆生成把视频、带 face ID 的人脸裁剪、带 voice ID 和时间戳的转写一起交给专门的 memorization 模型。输出既包含原子事件，也包含人物意图、关系、身份等高层结论，以及显式的人脸–声音等价事实。语义事实按向量相似度强化或弱化相关边；身份等价关系通过并查集建立 `character_N` 映射。这里的相似度规则不是经过验证的逻辑矛盾消解器。

控制器被提示先寻找名字与 character ID 的对应关系，再用 ID 查询。检索可按身份关联限制情景/语义文本候选，做向量匹配和片段级聚合，返回选中片段中的记忆，并避免重复返回已见片段。默认控制入口使用专门的 Control 权重、五轮文本 Search/Answer 动作，最后一轮要求回答且允许猜测。参考默认控制路径和本轮 oGMemory QA 都主要读取文本记忆，并不在每题重新读取原始画面。

3.2 关键差别：身份和语义记忆是否进入问答路径

维度	M3-Agent 参考路径	本次 oGMemory 路径
记忆组织	实体中心的单视频多模态图	Raw–Extracted–Memory 来源层次与 SQL 图
身份信息	生成时注入 face/voice ID，检索时使用等价映射	生成身份关系，但默认 Search 未显式使用该映射
语义记忆	模型推断高层事实、身份等价与边权更新	按视频拼接描述、集合去重，描述上限 50 KB
默认召回	情景与语义文本；实体关联约束；片段聚合	情景 ExtractedNode、转写词法召回、RRF 与邻近片段
嵌入	text-embedding-3-large	BGE-M3，1024 维，本地 GPU
控制	专门权重，5 轮，最后允许猜测	MiniMax 原生工具，6 轮，180 秒循环预算
存储与审计	VideoGraph、每视频 pickle	SQL/向量索引、账号/视频过滤、阶段回执与实验审计
默认评分	GPT-4o 二值 Yes/No	MiniMax 的 0/0.5/1 参考均分

oGMemory 不是简单把 M3-Agent 的图换成 SQL，也尚未完整复现其身份驱动的语义记忆问答机制。本轮更明确的优势方向是持久化、来源可追溯、失败处理和转写增强检索；参考实现更直接地把身份等价与高层语义事实接入回答链路。二者都是实现差异，而非已经通过对照证明的质量胜负。oGMemory 也并非整管线原子事务；本实验用独立数据库规避旧片段 ID 的跨实验冲突。

3.3 不能直接比较现有分数的原因

1. **评分口径不同：**参考代码用二值 GPT-4o 评委，本轮是同模型分级评分。0.5 不能直接当作二值正确；建议对两组固定预测同时给出共同二值评分与共同分级评分。
2. **模型与预算不同：**专门训练的 memorization/control 权重、MiniMax、不同嵌入模型、轮数和输出预算会混淆架构归因。
3. **时间可见性不同：**参考控制入口读取 before_clip，本轮按 timestamp 使用 current_clip。以 30 秒零基切片作示意，study_05 首题在 03:45、before_clip=6，两种协议可能分别允许约 210 秒与 240 秒之前的证据。实际比较必须统一 source interval 截止条件。
4. **媒体输入不同：**参考预处理的 5 fps 不等于其模型最终看到固定帧数，模型的视频处理器还有自身采样。本轮是每片段前缀最多 16 帧；相同视频和切片长度不保证相同视觉覆盖、转写或人物特征。

5. **工作负载不同：**下载现成图后只跑控制器是 QA-only，不能将其耗时与包含感知及记忆重建的完整管线比较。

预构建全视频图还需审计一个静态风险：后续片段可能更新较早语义节点的边权及身份锚点，仅删除未来文本节点不必然恢复历史图状态。这不是已经测出的泄漏率；严格因果对照可使用前缀图快照。

3.4 建议的两条评测线

第一条是**参考系统复现**：固定同一 65 题，先用可信的参考图和官方 Control 权重建立单独标记的 QA-only 基线；再视需要重建参考记忆做端到端比较。保存原始协议成绩，并在共同评委、共同时间截止条件下另行比较。

第二条是**同模型架构消融**：统一生成/回答模型、嵌入、评委、帧/音频预算、可见时间、回答策略和计算预算，只比较实体/等价关系检索与片段/转写检索等结构差异。这种移植应称为 M3-Agent-style 或 adapted，而非官方权重成绩。top-k 也不能只对齐数值：两个片段的全部原子记忆不等于八个情景节点及其邻居。

复现前还应检查本地代码的接口不一致：README 数据示例使用 `intermediate_path`，而入口读取 `intermediate_outputs`；提示词给出单数 `video_description`，读取代码却取复数 `video_descriptions`；片段遍历未显式数字排序，而部分截断逻辑依赖插入顺序。这些是需要 smoke test 和独立补丁记录的问题，不代表论文报告的实验一定失败。完整源码锚点、对照矩阵与部署前置条件见 `docs/m3_agent_comparison.md`。

4 实验设置

项目	设置
数据	`/data/m3_data/annotations/robot.json` 与原始 robot 视频
抽样	100 个候选排序后 seed=42，无放回选取 5 个，不按成绩换样本
记忆 / QA / 评委	远端 `MiniMax-M3.1-Flash`，用户指定 API 端点
正式输出预算	记忆 8192，QA 8192，评委 2048 tokens
推理参数	thinking=adaptive，reasoning_effort=medium；不发送 temperature
运行方式	完整视频，SQL 图，强刷主要抽取环节，不导入历史记忆
隔离	专用数据库、账号与向量表；不覆盖历史实验
计算环境	本地 T4 服务；音频阶段使用物理 GPU 2；情景生成 4 workers

视频	时长（秒）	题数
`study_05`	2044.889	12
`gym_03`	2033.514	11
`bedroom_04`	1650.684	11
`study_18`	2498.519	14
`kitchen_20`	1887.527	17

原始 wrapper 配置写 `omni-3b`，本地实际提供 `omni-7b`。首次试运行纠正名称并使用独立数据库，遇到缺失 vector 扩展后完成环境修复。随后用户要求改用 MiniMax-M3.1-Flash，故于 17:56 停止小模型进程树，保留已生成的部分记忆和失败日志，**不将中断试运行视为完整基线成绩**。正式 MiniMax 实验使用新数据库并重新生成记忆，三类 LLM 均使用指定模型。由于模型和输出预算均变化，不能据此计算“仅换模型”的质量增益。首次 MiniMax/max 正式尝试的首片段也出现 8192 tokens 全部用于推理、没有正文。同一输入改用 medium 后输出 1451 tokens（推理 431），获得完整记忆。因此另建本次 adaptive/medium 正式实验，重新生成全部记忆，保留 max 尝试作诊断。这只是单片段可运行性证据，不是 medium 优于 max 的全数据集质量结论。可选并发默认值仍为 1；本次设为 4，按清单顺序汇总结果，并保留逐片段失败。实际请求使用 `max_completion_tokens`，包括推理与最终输出；用户示例中的 500 tokens 只用于文本连通性测试。`study_05` 曾用于历史开发，所以本次不属于独立留出测试。

5 指标与失败处理

对于固定的 $N = 65$ 个问题，自动评委输出 $s_i \in \{0, 0.5, 1\}$。题目加权均分与视频宏平均分别为：

$$S_{\text{micro}} = \frac{1}{N}\sum_{i=1}^{N} s_i, \qquad S_{\text{macro}} = \frac{1}{5}\sum_{v=1}^{5}\frac{1}{N_v}\sum_{i\in v} s_i.$$

缺失答案与执行失败在端到端效用分中计零，同时单列缺失数、记忆覆盖和有效答案率。评委服务故障与模型答错分开：存在未评分的有效答案时，不将故障伪装成质量零分。题型采用数据集原始标签组合分组，不对多标签重复计数。

同一 MiniMax-M3.1-Flash 同时生成和评分，容易产生相关偏差；自动均分不是精确匹配准确率，也不是独立人工核验准确率。仅五个视频且题目在视频内相关，本报告不提供不恰当的独立题目置信区间，也不将单配置结果描述为相对于其他方法的因果提升。seed=42 只固定视频抽样；远端模型没有固定生成 seed，后端权重版本也不能由本地锁定。因此保存原始响应是可追溯性要求，不能保证再次运行逐字复现答案。

6 首轮固定配置运行结果

以下保留首轮原始统计；定向恢复和共同评委重评另列，不用后续结果覆盖首轮失败。管线结束状态为 `failed`。固定 65 题中保存 51 条 QA 记录，45 条答案非空且没有运行错误。题目加权自动均分为 **0.4692**，视频宏平均为 **0.4754**。评委错误 0 个。 分类表按原始标签分别计分，多标

视频	题数	有效答案	记忆/片段	索引	自动均分
`study_05`	12	9	69/69	69	0.2917
`gym_03`	11	10	68/68	68	0.7727
`bedroom_04`	11	9	56/56	56	0.6364
`study_18`	14	0	83/84	0	0.0000
`kitchen_20`	17	17	63/63	63	0.6765

签题重复进入多个分组；不能将分类题数相加作为总分母。总体均分仍严格按固定全集计算。SQL

标签	题数	有效答案	自动均分
Cross-Modal Reasoning	21	14	0.4286
General Knowledge Extraction	25	18	0.4200
Multi-Detail Reasoning	28	16	0.3393
Multi-Hop Reasoning	1	1	1.0000
Person Understanding	21	18	0.7381

环节	逻辑调用	输入 tokens	输出 tokens	推理 tokens
记忆	340	1587131	475023	147270
问答	241	14823188	72366	54743
评委/其他文本	45	28476	3423	1375

审计发现悬空或跨账号关系 0 条。各视频的阶段状态、失败清单和向量覆盖见机器审计文件。用量来自实际收到的 API usage，不等于账单金额。逻辑调用耗时包含网络、排队、推理与 SDK 重试，并发请求耗时和不等于整轮墙钟时间。预检与前序中断尝试另行保存，不混入本表。

6.1 首视频逐题审计与局限

2026 年 10 月 31 日 20:09 对 study_05 单独完成了一次临时评分：12 题中 9 题有效回答、3 题循环超时；2 题满分、4 题半分、6 题零分，均分 0.3333，评委错误为 0。正式五视频统一评分另行执行，不取两次评判中的较高者；故本节临时分与最终总表可能因评委波动而不同。本节只审计首视频的预测、金标和调用记录，不是五视频完整错误分布，也没有通过观看全部原视频独立核验金标。

- 彩纸回答在桌面，金标为最右书柜顶层抽屉；可能混淆原始存放与使用位置。
- 树的总数回答 2，金标为 1，回答将 “再做一棵” 的计划用作完成依据。
- 树干步骤回答 3，与金标一致，但引用理由仍需核实，不能仅凭数值匹配证明推理过程正确。
- 书包回答桌面，金标为桌子左侧，却获临时半分；说明自动评委可能偏宽。
- 装饰物答纸苹果，金标是黏土苹果，对象类别部分正确但材质错误。
- 叶子步骤、是否只关心学习和剪刀次数三题循环超时，没有有效答案；它们不是评委故障。

首视频 QA 记录了 60 次逻辑模型调用、累计 3,994,009 输入 tokens，单次输入峰值 147,951 tokens。长上下文与循环超时并存，支持优先检查检索证据累积和迭代效率；但没有严格消融，不能认定所有超时均由上下文大小导致。下一步可冻结同一份记忆，仅切换已有有界上下文机制，分别比较答案质量、覆盖、输入量与耗时。

6.2 另两视频的补充审计

23:10 的临时评分中，gym_03 为 8 题满分、3 题零分，均分 0.7273；其中一题超时，另两题分别把果汁的中层位置答成底层、把护腰的顶层位置答成中层。训练方式、热身道具和教练职业等

回答与金标匹配。bedroom_04 为 7 题满分、4 题零分，均分 0.6364；其中两题超时，另两题是过去偏好的演员答错，以及将 Mia 的薯片偏好答成巧克力。这些例子提示应继续检查空间细节、人物–偏好绑定和时序转换，但不构成已定位到某个具体模块的因果证据。两视频 QA 输入峰值分别为 131,454 和 144,546 tokens，说明长检索上下文现象不只存在于首视频。

7 2026 年 11 月 1 日：study_18 恢复与片段容错

首轮 study_18 的第 52 号片段返回人物/实体片段，而不是完整情景记忆，被校验器拒绝，导致后续索引和 14 题问答未执行。本次在首轮数据库的独立克隆上定向恢复，不覆盖首轮数据库或成绩。

恢复仅新增 1 条记忆，复用的 83 条正文及结构化内容逐项不变，最终完成 84/84 条记忆和索引；14/14 题有效回答，无超时和评委错误。恢复视频参考均分为 **0.3929**。保持原四视频的答案与评分不变，仅补齐该视频后，65 题组合均分为 **0.5538**，有效答案 59/65。这是覆盖恢复，不是对所有题重跑后择优，也不是模型或记忆架构的独立增益；首轮 0.4692 的记录仍完整保留。共同评委下的 M3-Agent 对照属于另一次评分。

oGMemory 的改动已提交到 `m3_dev_1031`：`99b22866` 保存模型推理参数和有界并发，`40ac1dcd` 增加无效输出重试及显式部分覆盖，`c992d45b` 保证连接指纹不包含凭据及其哈希。域无效输出可额外重试一次；若仍有少量失败，只有至少 95% 覆盖、回执与图一致、且没有旧失败节点可能混入时，才允许索引与问答继续。缺失片段进入提示和每题回执；全量完成的续跑判定不会误接受部分证据。鉴权、存储或低覆盖继续失败关闭。

相关扩展测试为 1063 passed、1 deselected；排除的一项音频重建重复节点测试已在修改前源码复现，不属于本次引入。另有独立 SQL 故障注入：强制片段 52 连续失败，剩余 83 条仍实际建索引，测试 QA 继续并披露缺失，最终退出码保持 2。该测试使用 stub 回答，不计入模型成绩。

8 同模型 M3-Agent 适配对照（2026 年 11 月 1 日）

本组从原视频重新计算 M3 感知和记忆，不复用 oGMemory 的情景/语义记忆或数据集预生成图。同一份新 M3 记忆搭配原生工具移植和参考 Action 文本协议两种控制器，分别运行全部 65 题，不择优拼接。两组官方检查点没有部署，因此这是适配实验。 本组 oGMemory 的均分比 M3

方法	有效答案	65 题参考均分
oGMemory（恢复后固定答案）	59/65	0.5462
M3-Agent 适配：参考 Action 文本协议	65/65	0.4615
M3-Agent 适配：原生工具移植诊断	28/65	0.2154

参考文本协议版高 0.0846。这仅适用于当前五视频和适配设置，不能声称官方 M3-Agent 被全面超越。原生工具诊断版和参考文本版的记忆完全相同，但控制器完成率差别明显；文本版保留末轮允许合理猜测的指令，有答案不等于有充分事实依据。统一评委的两条限流失败仅补评失败项，最终三组评委错误均为零。oGMemory 预测没有修改；共同评分 0.5462 与此前组合评分 0.5538 的差异来自重评波动。所有原始故障和先前评分均保留。65 题的实际时间截止点已逐项核对一致。五视频的采样帧和 WAV 逐文件一致；四视频转写一致，study_18 的 clip 61 有四条转写/时间差异。

视频	oGMemory	M3 参考文本	M3 原生工具
study_05	0.3333	0.5417	0.2083
gym_03	0.7273	0.5909	0.2273
bedroom_04	0.6364	0.5455	0.2727
study_18	0.3571	0.2857	0.0000
kitchen_20	0.6765	0.4118	0.3529

M3 额外使用身份裁剪，感知后端、控制提示和原版策略存在已记录适配，故不是严格单变量架构实验。服务负载、开发停顿和限流也使总墙钟不可直接作严格加速比。详细三列逐题结果、原函数指纹、输入核对与方法偏离见 experiments/m3_end_to_end_comparison_20261101/。

9 改进方向与后续对照设计

1. **运行可靠性：**启动前校验在线模型名、数据库扩展和多模态完整输入；统计记忆截断、QA 上下文超限与评委异常，分别处理而非笼统归为低准确率。
2. **视觉覆盖：**固定 16 帧预算，对比前缀采样与整片段等距采样，再讨论动作自适应采样，避免同时改变帧数和采样位置而无法归因。
3. **有界上下文：**冻结同一份记忆，仅切换现有 qa_context，同时报告质量、请求大小、调用次数和失败率，不只报告 token 缩减。
4. **事实和时序：**为对象位置、材料、人物归属保存可定位证据；区分计划、建议与已完成事件；计数使用可去重事件时间轴而非检索条数。
5. **图结构价值：**明确语义节点与身份边何时进入检索，设计情景记忆、加入身份关联、加入分层语义摘要的逐项消融。
6. **评测可信度：**固定独立评委并人工抽查零分、半分和计数/空间问题，将本轮样本作为开发集，另设未调参的新视频集验证泛化。

以上属于后续建议；除结果节明确记录的恢复处理外，不能表述为本次已实现或已验证的算法增益。

10 复现与产物

先在交互式 bash 中 source 用户的 ~/.bashrc 并导出 MINIMAX_API_KEY，在 memory-eval 根目录执行 bashscripts/run_m3_flash_medium.sh；私有配置路径由脚本固定，提交版仅保留脱敏配置和配置哈希。实验完整媒体、原始模型输出与运行日志位于 runs/，默认不入 Git。轻量结果位于 experiments/m3_flash_medium_20261031/，包括抽样 manifest、输入清单、版本记录、逐题 CSV/JSONL、机器统计与测试日志。具体恢复步骤和结果状态以同目录报告为准。

统计脚本 scripts/summarize_m3.py 校验标注哈希、固定题数、重复答案、样本外记录以及评分与预测的一致性。它不会悄悄从多轮尝试里选择最高分。兼容修改后实际执行 M3、LLM provider 与管线集成测试：976 passed；外层统计脚本另有 9 项测试通过。LaTeX 使用 ctexart

与 XeLaTeX，在工作区根目录执行 bashscripts/build_report.sh，或进入本目录执行 make。脚本检查中文依赖，用 latexmk 自动完成交叉引用收敛，只在成功时发布 latex/report.pdf；构建日志与输入哈希保存在 latex/build/。

参考文献

[1] oGMemory dev，固定提交 8c86c3ed。主要实现：m3/pipeline/、m3/episodic_memory.py、m3/control_adapter.py、m3/index_episodic.py、m3/temporal.py、m3/eval.py。

[2] 本地实验协议：docs/m3_random_subset.md、docs/m3_bounded_context.md、docs/m3_semantic_consolidation.md。历史文档的成绩未用作本次实测结果。

[3] 本地 M3-Bench 数据副本：/data/m3_data/，robot 标注版本哈希见 sample_manifest.json。

[4] 本地 M3-Agent 参考仓库，提交 0e3e419；m3_agent/control.py、mmagent/retrieve.py、mmagent/videograph.py 与 mmagent/memory_processing_qwen.py。本节为参考代码分析；后续同模型适配评测不等同于官方权重复现或论文成绩。