oGMemory：面向长视频问答的多模态记忆系统架构设计与实验评估

oGMemory / memory-eval

2026 年 11 月 2 日

摘要

长视频问答要求将分散的视觉、语音与人物线索转化为可长期保存、按需检索的证据。本文面向原本不具备多模态记忆能力的 oGMemory，设计并实现从媒体感知、情景记忆构建、来源关联与索引到多轮检索问答的完整多模态记忆系统。系统以统一来源组织连接视频片段、结构化事实与回答证据，通过片段与事实的混合召回保留局部细节，并以来源位置去重和有界增量交付控制重复上下文。在 M3-Bench 固定五视频、65 题的固定记忆 QA 评估中，使用相同 MiniMax-M3.1-Flash 模型与共同自动评委，oGMemory 来源事实组合两次运行均分为 0.5962，高于 M3-Agent 参考适配的 0.4615；严格增量方案获得 0.5846，65 题均有效回答，相较本系统同期有界上下文基线减少 38.2% 的 QA 输入和 63.6% 的未缓存输入。结果展示了来源可追溯、细粒度证据检索和受控上下文交付相结合的应用价值。

1 Introduction

多模态记忆的目标并非保存尽可能多的原始媒体，而是在有限计算和上下文预算下，为后续问题保留可定位、可关联的证据。长视频中的回答可能依赖多个时刻的物品变化、人物偏好、对话内容与视觉状态。直接将全部视频描述和转写拼接给语言模型，会使无关信息和重复检索结果累积；过早压缩成短摘要，又可能丢失姓名、数量、动作对象等决定答案的细节。

构建这样的记忆系统需要贯通三个环节。首先，**多模态感知与记忆表示**需要把视频帧、语音转写、人物与事件组织到共同的片段和时间坐标中，使不同模态的观察能够联合使用。其次，**证据组织与检索**需要兼顾片段背景和局部细节，既能回答某个时刻发生了什么，也能定位分散在多段对话或画面中的相关事实。最后，**按需交付与问答**需要将检索结果转化为语言模型可消费的有界上下文，避免反复发送相同内容，同时允许继续补充证据。

原有 oGMemory 不具备多模态记忆能力。本文以其通用记忆基础设施为承载，从头设计并实现多模态记忆子系统：接入视频与音频，生成结构化情景记忆，建立来源关系及多粒度索引，再通过带时间约束的检索与多轮问答使用这些记忆。本文的工作范围覆盖整条多模态处理链路，而非对一个预先存在的多模态记忆模块进行局部优化。核心设计包括：

- **来源贯通的记忆架构**。将媒体、抽取结果和记忆关联存储，保留片段时间及证据出处，使记忆可检查、检索可回源、片段失败可定位。
- **兼顾背景与细节的检索**。联合情景片段、转写和原文事实窗口，结合有来源的人物条件，使局部证据能够在保留片段背景的同时进入问答。

- **受控的证据消费**。以已交付的来源位置为粒度增量补充证据，结合整体输入预算与回答收尾机制，降低多轮检索中的重复输入。

我们在 M3-Bench 的五个视频上构建并使用该系统，并以相同模型适配的 M3-Agent 作为对照。实验部分固定已生成的记忆，比较系统内部不同检索和交付配置，报告共同自动评分与 QA 输入。这一评估用于检验问答阶段的设计取舍；系统完整架构与本轮实验测量范围分别说明。

2 Related Work

2.1 多模态记忆与长视频理解

长视频记忆的一条路线是在视觉表示层压缩历史信息。MovieChat[1] 以视觉 token 为记忆载体，借鉴短期与长期记忆机制，将密集视频信息组织为稀疏记忆，以支持长视频理解。另一条路线把视频转化为可查询的结构化观察。VideoAgent[2] 同时保存时序事件描述和以对象为中心的跟踪状态，通过片段定位、对象记忆查询等工具，由语言模型交互式求解视频任务。这些工作分别体现了表示压缩与结构化检索两种设计思路。

M3-Agent[3] 进一步面向持续的视听输入，构建以实体为中心的多模态记忆，同时保存情景事实与高层语义知识，并通过迭代检索进行推理。其人脸和声音线索参与人物关联，使不同模态中的观察能够围绕人物组织；配套 M3-Bench 评估人物理解、跨模态推理等长视频记忆能力。与仅压缩视觉表示的路线相比，这类系统更关注可持续更新的实体与事实记忆。本文同样从视频与音频构建记忆，但以源片段、字段位置和时间边界连接结构化证据，强调检索结果的可回溯性及多轮问答中的细粒度交付。

2.2 文本记忆与语言智能体

文本记忆研究为记忆组织和有限上下文管理提供了基础。Generative Agents[4] 以自然语言保存经历，通过检索和高层反思支持行为规划，体现了从观察到抽象记忆的组织方式。MemGPT[5] 借鉴操作系统分层存储，在有限上下文和外部记忆之间管理信息流，将上下文管理作为智能体控制的一部分。二者分别突出记忆内容的组织与工作上下文的调度。

面向长期对话，Mem0[6] 通过抽取、整合和检索重要信息维护持久记忆，并提出图式变体表达关系；A-MEM[7] 借鉴卡片笔记法，为记忆生成结构化属性、建立关联，并随新记忆加入更新既有记忆表示。这些系统说明，持久记忆不只是扩大提示窗口，还需要选择、关联和维护信息。但从文本对话迁移到视听输入，还需处理感知误差、时间对齐和人物归属。本文将来源约束、事实检索与受控上下文连接起来，不把文本相关性直接当作跨模态身份等价。上述论文用于定位设计，并未全部纳入本次五视频实验对比。

2.3 与 M3-Agent 的设计区别

M3-Agent 强调紧凑的情景/语义事实和实体关联；本文在 oGMemory 中新增的多模态子系统，将媒体、抽取结果与记忆关联存储，默认 QA 检索情景节点及其来源事实。事实窗口保留原文位置，不额外生成高层语义推断；人物条件采用来源中的姓名/角色软排序，而不是已核实的人脸–声音–姓名链接。

在本文审阅的参考实现中，M3-Agent 普通控制路径主要每次取 top-2 片段，记录已交付片段并追加新片段；本文按源位置去重，允许补充同一片段中尚未看到的事实。上述控制细节来自本地实现审阅，不是对所有多模态记忆方法的通用假设。本次对照保留 M3-Agent 参考控制思路，以共同模型替代其专用记忆和控制权重，因此是**同模型参考适配**，不是原论文官方权重或成绩复现。

3 Method

3.1 总体架构与数据流

系统建立“媒体接入与感知、记忆构建与存储、索引与检索、上下文交付与回答”四层处理链路。通用存储与算子机制由 oGMemory 承载，视频/音频处理、情景记忆生成、多模态来源关联、面向视频的索引检索及问答控制均属于本文新增的多模态能力。离线构建层把连续媒体转化为持久记忆；在线问答层根据问题和时间范围选择证据，无需在每次回答时重新处理完整视频。表1概括模块职责。

表 1: oGMemory 多模态记忆子系统的层次与数据流。

层次	主要处理	输出与接口
媒体感知	视频切片、帧与音频提取、转写、人物线索	带片段及时间来源的媒体与观察
记忆构建	多模态情景抽取、来源关联、视频级整合	片段描述、人物、事件、实体及支持关系
索引检索	片段/事实向量、转写召回、人物软排序	经账号、视频、时间与哈希校验的证据
检索问答	Search/Answer 循环、增量交付、预算控制	可回溯证据的回答及运行记录

3.2 媒体感知与结构化情景抽取

视频按 30 秒切片，每段创建视频源节点，并关联抽取的图像帧及 16 kHz 单声道音频。视觉处理提取帧及人脸线索；音频处理使用 Whisper 转写、pyannote 说话人分离及 ECAPA 声纹特征。图像、可用音频和转写进入情景记忆生成算子，形成包含 description、characters、events 和 entities 的片段级结构化输出，分别记录场景描述、人物、事件及实体。这一表示将视觉观察与对话内容置于同一片段背景下，为后续文本化检索提供统一入口。当前帧采样为 1 fps 取前至多 16 帧，其覆盖限制在讨论中说明。

片段处理保留独立状态和失败清单。无效结构化输出可有限重试，仍失败的片段被显式记录；继续处理其他片段后按覆盖门槛判断整体是否合格，避免单片段故障直接中断全部视频，也不把缺失片段伪装成完整记忆。

3.3 来源存储、人物线索与时间约束

原始媒体作为 Raw 节点，结构化抽取作为 Extracted 节点，持久记忆作为 Memory 节点，三者通过来源及支持关系连接。问答默认检索情景抽取节点，并可由节点及字段位置返回原片段。视频级记忆通过描述拼接和集合去重整合，维护支持与演化关系；它不额外生成高层语义推断。人脸和声音聚类保留人物关联线索，但这不等于已核实的跨模态姓名绑定，也不意味着默认 QA 直接遍历所有身份关系。

所有检索受账号、视频和可用时间限制。本文实验采用`current_clip` 协议，允许使用问题所在片段末尾之前的证据；事实可用时间保守地取其来源片段末尾，不读取未来片段建立姓名映射。由于该边界可能晚于问题时刻，本文不将这一设置称为严格因果在线问答。

3.4 来源事实索引与混合召回

我们将源记忆拆成三类窗口：description 的局部原文、相邻三条 ASR 转写，以及完整的事件、人物或实体项。每个窗口记录源节点、字段位置或字符范围、内容哈希及可用时间。相同文本在不同时间出现仍是不同观察；窗口数不能直接当作事件发生次数。

在五视频上，7,965 个窗口由 BGE-M3 编码为 1024 维向量。检索层并行使用片段向量、转写和事实窗口召回；事实命中按最大分数聚合到源节点，再与片段及转写候选排序等权融合：

$$\mathrm{RRF}(d) = \sum_{r \in \mathcal{R}} \frac{1}{k + \mathrm{rank}_r(d)}.$$

其中 $\mathcal{R}$ 表示参与融合的排序，k 为平滑常数。候选进入上下文前需再次验证范围与源内容哈希，避免旁路索引绕过权限或引用过期内容。该索引是面向小规模固定数据的密集检索原型，而非生产级 ANN 或动态语义图。

3.5 显式人物条件软排序

在已通过范围过滤的候选内，查询若完整匹配来源中的 name 或 role，则给予有限的排序奖励，并提高对应人物描述的准入优先级。我们不硬性排除无匹配候选，避免将“没有写姓名”误当成“不属于此人”。局部 `SPEAKER_00` 等标签不作为跨片段身份，角色相同也不自动合并人物。这是一种来源声明驱动的检索条件，而不是身份识别算法。

3.6 严格增量证据交付与回答收尾

每题维护已实际发送的来源位置集合 D_t。第 t 轮检索的候选事实为 C_t，只从 $C_t \setminus D_t$ 中选入新证据；过去的工具消息保持不变。这种去重既减少整片段重传，也允许补充同源片段的不同事实。停搜依据实际新增可见事实，而非仅检查是否出现新节点。

严格增量方案 E 将每轮新增额度设为 3500，按照实际模型投影的 token 估计计数，不把未发送的审计字段计入额度基数。全部历史还受整体有效输入预算约束：

$$B_{\mathrm{input}} = 32768 - 8192 - 2048 = 22528,$$

分别为操作窗口、输出预留与安全余量。单次新增节点上限不等于整个历史的节点上限；必要时可重建上下文并重置交付集合，本轮 E 未触发重建。收尾时仅提供 Answer 工具并请求必选；普通文本仍由既有兼容路径接收，因此该设置不是严格的原生工具输出保证。

4 Evaluation

4.1 数据、设置与指标

固定 M3-Bench[3] robot 子集的五视频（原抽样 seed=42），共 65 题，视频不按成绩替换。记忆生成、QA 与自动评委均配置 MiniMax-M3.1-Flash，`thinking=adaptive`、`reasoning_effort`

=medium；QA 输出预算 8192，评委 2048，最多 6 轮及 180 秒软循环预算。软预算不等于单请求或端到端硬超时。此次比较固定各自已生成的记忆，M3-Agent 使用独立生成的 340 片段记忆，而非借用 oGMemory 记忆。

最终共同评分覆盖 11 条完整轨迹的 715 条答案，按 seed=1102 交错安排，评委不接收方案名。每题评分 $s_i \in \{0, 0.5, 1\}$，主指标为 $S = \frac{1}{65}\sum_{i=1}^{65} s_i$；无效答案计零，并单列有效率。所有评分完成，无评委错误。这是**自动评分均值，而非人工准确率**。重复运行不增加独立题目数；主表只用本批共同评分，不拼接历史较高分数。QA 输入统计覆盖全部题目及多轮调用，含缓存输入，并另列未缓存部分；不包含感知、历史记忆生成或评委调用。

4.2 同模型主结果

B 为本文多模态子系统的有界上下文基线，而非新增多模态能力之前的 oGMemory；S 组合来源事实索引、人物条件与修正的增量交付；E 进一步使用严格 3500 新增额度和收尾请求。表2同时保留 B 的历史固定轨迹与同期重复，避免仅选较弱基线。两次运行行的 token 数为每次运行的平均，非两次总和。

表 2: 五视频共同评分与 QA 输入。M 表示百万 token；括号为重复次数。

方案	均分	有效回答	输入 (M)	未缓存 (M)
M3-Agent 参考适配（2）	0.4615	65/65	0.561	0.194
B 历史固定轨迹（2）	0.5962	65/65	4.756	4.138
B 同期重复（1）	0.5308	65/65	4.721	4.137
S 来源事实组合（2）	0.5962	65/65	3.433	2.081
E 严格增量（1）	0.5846	65/65	2.916	1.508

S 两次得分分别为 0.5846 与 0.6077，均值恰好等于 B 两条历史答案的本批重评分均值。同期 B 仅 0.5308，显示运行波动不可忽略。E 相对同期 B 的总输入减少 38.2%，未缓存输入减少 63.6%；相对 S 两次平均进一步减少 15.1% 和 27.5%。因此主要证据是**保持此前质量附近的输入效率改善**，不是已确认的无损压缩或稳定提分。E 只有一次运行，独立重复因额度低于预设启动门槛未执行。

相对 M3-Agent 两次均值，S 和 E 分别高 0.1346 和 0.1231，但 E 的总输入仍为其 5.20 倍，未缓存输入为 7.77 倍。M3-Agent 的紧凑事实和少量片段交付仍有明显输入效率优势。这些 token 比例不能直接解释为费用或墙钟加速比。

4.3 分视频表现与消融

表3显示收益并非所有视频一致。E 在 study_18 和 kitchen_20 上高于同期 B 及 M3-Agent，但在 gym_03 上低于 B；study_18 绝对得分仍较低。M3-Agent 与 E 在 study_05、gym_03 上相同，不能将总分差解释为全面能力优势。

早期消融中，仅原文事实窗口 F 为 0.5000，增加姓名/角色条件 FI 为 0.4923，再加入初版增量交付 FIP 为 0.5462（64/65 有效，唯一协议失败计零）。这说明切短文本或显式人物条件本身不保证整体收益；S 包含多个组合变化，不能把其全部增益单独归于事实向量索引。数据集题型为重叠多标签，多跳推理仅 1 题，不据此判断泛化能力。

E 的 370 次 QA 调用中未发生上下文重建，305 次相邻消息前缀检查全部保持；该检查不含

表 3: 分视频自动评分。S 和 M3 为两次均值，B 为同期运行。

视频	题数	B	S	E	M3
study_05	12	0.4167	0.4583	0.4583	0.4583
gym_03	11	0.6818	0.6591	0.6364	0.6364
bedroom_04	11	0.7273	0.7955	0.7727	0.6364
study_18	14	0.3214	0.4286	0.4643	0.2679
kitchen_20	17	0.5588	0.6618	0.6176	0.3971

工具 schema，也不保证供应商缓存命中。57 次 Answer-only 请求中 41 次返回原生工具，16 次普通文本由兼容路径接受；45 秒回答预留没有实际触发，不能把本轮效果归因于该预留。来源位置审计未发现时间越界或重复交付，但来源一致不代表事实或答案必然正确。

4.4 公平性与复现边界

相同模型并不等于严格单因素对照。M3-Agent 参考适配采用 Action 文本协议和末轮猜测，oGMemory 采用原生工具并强调证据不足时说明；参考方未加载专用训练权重。感知替换、BGE 嵌入适配和身份裁剪也构成差异：两边基础帧/WAV 相同，但 M3 额外使用至多 8 张身份人脸裁剪，study_18 的一个片段存在 4 处 ASR/时序差异。故分数差不能纯粹归因于存储结构、身份图或检索算法。

共同评委虽完成 715 条评分，但 714 个需模型评分任务的 usage 及逐响应模型标识未持久化（另 1 条无效答案自动计零）；配置与冻结代码可核查，历史响应 trace 无法恢复。全部 QA 用量记录完整，表中 QA 比较有效，**整轮总 token 和总费用不能完整报告**。详细逐题结果、配置与审计保留于本地实验目录，未以估算补账或重评替代原结果。

5 Conclusion and Discussion

本文为原本不具备多模态记忆能力的 oGMemory 构建了完整的多模态记忆子系统，贯通媒体感知、情景抽取、来源关联、混合检索与多轮问答。系统以可回源的记忆组织保留证据，以细粒度检索和增量交付控制问答上下文。在固定五视频上，来源事实组合达到与历史有界基线接近的自动评分，严格增量方案进一步降低输入。相同模型下，其得分高于 M3-Agent 参考适配，但输入仍显著更多。当前更合理的结论是质量–输入开销的折中改善，而不是已解决多模态身份或实现稳定全面提分。

限制包括五视频开发集、同模型自动评委、E 尚无重复，以及本轮仅评估固定记忆的 QA 路径。视觉前缀采样、ASR 错误和错误人物归属仍会限制检索；新增来源索引无法恢复未被感知的事实。此外，`current_clip` 不满足严格因果协议，重复试验也不能代替独立留出测试。

下一步应优先完成 E 独立重复与新视频验证，并用独立评委和人工抽查核验主要差异；在生成阶段引入可撤销、带时间来源的脸–声–姓名关联，单独测量身份错误；最后在统一感知和控制协议下重跑端到端实验，同时补齐用量采集。完整历史实验日志保留在仓库中，不作为本文主体展开。

参考文献

[1] Enxin Song, Wenhao Chai, Guanhong Wang, et al. MovieChat: From Dense Token to Sparse Memory for Long Video Understanding. *CVPR*, 2024. arXiv:2307.16449.

[2] Yue Fan, Xiaojian Ma, Rujie Wu, et al. VideoAgent: A Memory-augmented Multimodal Agent for Video Understanding. *ECCV*, 2024. arXiv:2403.11481.

[3] Lin Long, Yichen He, Wentao Ye, et al. Seeing, Listening, Remembering, and Reasoning: A Multimodal Agent with Long-Term Memory. arXiv:2508.09736, 2025.

[4] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, et al. Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442, 2023.

[5] Charles Packer, Sarah Wooders, Kevin Lin, et al. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560, 2023.

[6] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, Deshraj Yadav. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv:2504.19413, 2025.

[7] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, Yongfeng Zhang. A-MEM: Agentic Memory for LLM Agents. *NeurIPS*, 2025. arXiv:2502.12110.