oGMemory-m3：面向长视频问答的多模态记忆系统架构设计与实验评估

刘远见

2026 年 11 月 3 日

摘要

长视频问答要求将分散的视觉、语音与人物线索转化为可长期保存、按需检索的证据。本文提出 oGMemory-m3，从零设计并实现覆盖媒体感知、情景记忆构建、来源关联与索引及多轮检索问答的多模态记忆系统。系统新增记忆图谱存储、算子机制与声明式编排流程，将各处理模块组织为可配置、可追踪的执行链路。系统以统一来源组织连接视频片段、结构化事实与回答证据，通过片段与事实的混合召回保留局部细节，并以来源位置去重和有界增量交付控制重复上下文。在 M3-Bench 最新已完成实验的八视频、97 题配对子集上，使用相同 MiniMax-M3.1-Flash 模型、共享感知输入与共同自动评委，oGMemory 获得 0.5722 的自动评分均值，高于 M3-Agent 参考适配的 0.4381，并在八个视频中的六个取得更高评分。我们进一步报告建忆与问答的 token 开销及阶段耗时，将质量表现与系统处理成本放在同一评估范围内。结果展示了来源可追溯、细粒度证据检索和受控上下文交付相结合的应用价值。

1 Introduction

多模态记忆的目标并非保存尽可能多的原始媒体，而是在有限计算和上下文预算下，为后续问题保留可定位、可关联的证据。长视频中的回答可能依赖多个时刻的物品变化、人物偏好、对话内容与视觉状态。直接将全部视频描述和转写拼接给语言模型，会使无关信息和重复检索结果累积；过早压缩成短摘要，又可能丢失姓名、数量、动作对象等决定答案的细节。

构建这样的记忆系统需要贯通三个环节。首先，**多模态感知与记忆表示**需要把视频帧、语音转写、人物与事件组织到共同的片段和时间坐标中，使不同模态的观察能够联合使用。其次，**证据组织与检索**需要兼顾片段背景和局部细节，既能回答某个时刻发生了什么，也能定位分散在多段对话或画面中的相关事实。最后，**按需交付与问答**需要将检索结果转化为语言模型可消费的有界上下文，避免反复发送相同内容，同时允许继续补充证据。

本文从零构建 oGMemory-m3 多模态记忆系统，设计记忆图谱存储、算子机制及算子编排流程，接入视频与音频，生成结构化情景记忆，建立来源关系及多粒度索引，再通过带时间约束的检索与多轮问答使用这些记忆。本文的工作范围覆盖整条多模态处理链路，而非对一个预先存在的多模态记忆模块进行局部优化。核心设计包括：

- **算子化处理与声明式编排**。新增处理算子的封装、阶段配置与执行机制，以显式依赖连接感知、记忆、索引和问答，统一记录各阶段产物与执行状态。
- **来源贯通的记忆图谱**。新增以节点和关系组织媒体、抽取结果与记忆的存储方式，保留时间及证据出处，使记忆可检查、检索可回源，并为后续文本记忆迁移提供统一表示。

- **兼顾背景与细节的检索**。联合情景片段、转写和原文事实窗口，结合有来源的人物条件，使局部证据能够在保留片段背景的同时进入问答。
- **受控的证据消费**。以已交付的来源位置为粒度增量补充证据，结合整体输入预算与回答收尾机制，降低多轮检索中的重复输入。

我们以相同模型适配的 M3-Agent 作为对照，在共同感知输入上分别生成记忆、执行问答。本文只比较两套系统，不展开内部配置消融；以已完成的八视频配对子集报告逐视频质量、token 用量及处理时间，并明确区分已评测版本与仍在复测的新实现。

2 Related Work

2.1 多模态记忆与长视频理解

长视频记忆的一条路线是在视觉表示层压缩历史信息。MovieChat[1] 以视觉 token 为记忆载体，借鉴短期与长期记忆机制，将密集视频信息组织为稀疏记忆，以支持长视频理解。另一条路线把视频转化为可查询的结构化观察。VideoAgent[2] 同时保存时序事件描述和以对象为中心的跟踪状态，通过片段定位、对象记忆查询等工具，由语言模型交互式求解视频任务。这些工作分别体现了表示压缩与结构化检索两种设计思路。

M3-Agent[3] 进一步面向持续的视听输入，构建以实体为中心的多模态记忆，同时保存情景事实与高层语义知识，并通过迭代检索进行推理。其人脸和声音线索参与人物关联，使不同模态中的观察能够围绕人物组织；配套 M3-Bench 评估人物理解、跨模态推理等长视频记忆能力。与仅压缩视觉表示的路线相比，这类系统更关注可持续更新的实体与事实记忆。本文同样从视频与音频构建记忆，但以源片段、字段位置和时间边界连接结构化证据，强调检索结果的可回溯性及多轮问答中的细粒度交付。

2.2 文本记忆与语言智能体

文本记忆研究为记忆组织和有限上下文管理提供了基础。Generative Agents[4] 以自然语言保存经历，通过检索和高层反思支持行为规划，体现了从观察到抽象记忆的组织方式。MemGPT[5] 借鉴操作系统分层存储，在有限上下文和外部记忆之间管理信息流，将上下文管理作为智能体控制的一部分。二者分别突出记忆内容的组织与工作上下文的调度。

面向长期对话，Mem0[6] 通过抽取、整合和检索重要信息维护持久记忆，并提出图式变体表达关系；A-MEM[7] 借鉴卡片笔记法，为记忆生成结构化属性、建立关联，并随新记忆加入更新既有记忆表示。这些系统说明，持久记忆不只是扩大提示窗口，还需要选择、关联和维护信息。但从文本对话迁移到视听输入，还需处理感知误差、时间对齐和人物归属。本文将来源约束、事实检索与受控上下文连接起来，不把文本相关性直接当作跨模态身份等价。上述论文用于定位设计，并未全部纳入本次实验对比。

2.3 与 M3-Agent 的设计区别

M3-Agent 强调紧凑的情景/语义事实和实体关联；本文在 oGMemory 中新增的多模态子系统，将媒体、抽取结果与记忆关联存储，默认 QA 检索情景节点及其来源事实。事实窗口保留原文位

置，不额外生成高层语义推断；人物条件采用来源中的姓名/角色软排序，而不是已核实的人脸–声音–姓名链接。

在本文审阅的参考实现中，M3-Agent 普通控制路径主要每次取 top-2 片段，记录已交付片段并追加新片段；本文按源位置去重，允许补充同一片段中尚未看到的事实。上述控制细节来自本地实现审阅，不是对所有多模态记忆方法的通用假设。本次对照保留 M3-Agent 参考控制思路，以共同模型替代其专用记忆和控制权重，因此是**同模型参考适配**，不是原论文官方权重或成绩复现。

3 Method

3.1 总体架构与数据流

系统建立“媒体接入与感知、记忆构建与存储、索引与检索、上下文交付与回答”四层处理链路。记忆图谱存储、算子机制与声明式编排共同构成从零搭建的系统基础：图谱层组织原始输入、抽取事实、持久记忆及其关系，算子层实现各类处理，编排层连接阶段依赖与执行产物。视频/音频处理、情景记忆生成、多模态来源关联、面向视频的索引检索及问答控制在这一架构中协同工作。图谱层不将输入限定为视听媒体，为后续文本记忆接入同一记忆表示与关系体系预留路径。离线构建层把连续媒体转化为持久记忆；在线问答层根据问题和时间范围选择证据，无需在每次回答时重新处理完整视频。表1概括模块职责。

表 1: oGMemory-m3 的层次与数据流。

层次	主要处理	输出与接口
媒体感知	视频切片、帧与音频提取、转写、人物线索	带片段及时间来源的媒体与观察
记忆图谱	情景抽取、节点与关系存储、视频级整合	原始输入、事实、记忆及来源和支持关系
索引检索	片段/事实向量、转写召回、人物软排序	经账号、视频、时间与哈希校验的证据
检索问答	Search/Answer 循环、增量交付、预算控制	可回溯证据的回答及运行记录

3.2 算子机制与声明式编排

新增算子机制将媒体处理、特征抽取和记忆生成等操作封装为可调用单元，编排层通过注册的阶段处理函数将这些操作与存储、索引和问答步骤连接起来。阶段描述声明标识、类型、启用状态、参数与依赖；共享运行上下文传递媒体产物路径、账号和视频范围、图存储及索引服务。算子负责具体处理，编排层负责阶段衔接与执行记录，二者共同构成本文新增的处理框架。

流程采用声明式配置，而非在单一脚本中固定全部调用。例如，情景记忆生成依赖帧提取、音频提取和转写，记忆节点创建与索引构建依赖情景抽取结果。执行器检查阶段类型及依赖是否有效，在执行阶段前检查其前置状态，并统一记录输出、计数、错误和警告；可选阶段通过配置启停。对于具有完成性探测的阶段，可检查已有产物后跳过重复执行。这使处理配置与算子实现分离，便于替换组件、定位失败及恢复执行；它是系统架构能力，本文不将其单独归因为问答得分提升。

3.3 媒体感知与结构化情景抽取

视频按 30 秒切片，每段创建视频源节点，并关联抽取的图像帧及 16 kHz 单声道音频。视觉处理提取帧及人脸线索；音频处理使用 Whisper 转写、pyannote 说话人分离及 ECAPA 声纹特

征。图像、可用音频和转写进入情景记忆生成算子，形成包含 description、characters、events 和 entities 的片段级结构化输出，分别记录场景描述、人物、事件及实体。这一表示将视觉观察与对话内容置于同一片段背景下，为后续文本化检索提供统一入口。每个 30 秒片段按 1 fps 收集至多 30 帧，再从整个采集序列均匀选取至多 16 张基础模型帧；标准片段的模型输入时间范围约为 0–28 秒，而非仅覆盖前 16 秒。这一规则改善时间覆盖，但仍可能遗漏短暂动作或细小视觉线索。

片段处理保留独立状态和失败清单。无效结构化输出可有限重试，仍失败的片段被显式记录；继续处理其他片段后按覆盖门槛判断整体是否合格，避免单片段故障直接中断全部视频，也不把缺失片段伪装成完整记忆。

3.4 记忆图谱存储、人物线索与时间约束

本文新增记忆图谱存储方式，以节点表达不同层次的信息，以关系表达来源、支持和演化。在多模态流程中，原始媒体作为 Raw 节点，结构化抽取作为 Extracted 节点，持久记忆作为 Memory 节点，三者通过来源及支持关系连接。图谱提供结构化事实及证据链的组织方式，向量与词法索引提供按问题检索的入口，两者分别承担关联存储与相关性召回。问答默认检索情景抽取节点，并可由节点及字段位置返回原片段。视频级记忆通过描述拼接和集合去重整合，维护支持与演化关系；它不额外生成高层语义推断。人脸和声音聚类保留人物关联线索，但这不等于已核实的跨模态姓名绑定，也不意味着默认 QA 直接遍历所有身份关系。

所有检索受账号、视频和可用时间限制。本文实验采用`current_clip` 协议，允许使用问题所在片段末尾之前的证据；事实可用时间保守地取其来源片段末尾，不读取未来片段建立姓名映射。由于该边界可能晚于问题时刻，本文不将这一设置称为严格因果在线问答。

3.5 来源事实索引与混合召回

我们将源记忆拆成三类窗口：description 的局部原文、相邻三条 ASR 转写，以及完整的事件、人物或实体项。每个窗口记录源节点、字段位置或字符范围、内容哈希及可用时间。相同文本在不同时间出现仍是不同观察；窗口数不能直接当作事件发生次数。

每个视频的来源窗口由 BGE-M3 编码为 1024 维向量，并形成独立的事实索引。检索层并行使用片段向量、转写和事实窗口召回；事实命中按最大分数聚合到源节点，再与片段及转写候选排序等权融合：

$$\mathrm{RRF}(d) = \sum_{r \in \mathcal{R}} \frac{1}{k + \mathrm{rank}_r(d)}.$$

其中 $\mathcal{R}$ 表示参与融合的排序，k 为平滑常数。候选进入上下文前需再次验证范围与源内容哈希，避免旁路索引绕过权限或引用过期内容。该索引是面向小规模固定数据的密集检索原型，而非生产级 ANN 或动态语义图。

3.6 显式人物条件软排序

在已通过范围过滤的候选内，查询若完整匹配来源中的 name 或 role，则给予有限的排序奖励，并提高对应人物描述的准入优先级。我们不硬性排除无匹配候选，避免将“没有写姓名”误当成“不属于此人”。局部 `SPEAKER_00` 等标签不作为跨片段身份，角色相同也不自动合并人物。这是一种来源声明驱动的检索条件，而不是身份识别算法。

3.7 严格增量证据交付与回答收尾

每题维护已实际发送的来源位置集合 D_t。第 t 轮检索的候选事实为 C_t，只从 $C_t \setminus D_t$ 中选入新证据；过去的工具消息保持不变。这种去重既减少整片段重传，也允许补充同源片段的不同事实。停搜依据实际新增可见事实，而非仅检查是否出现新节点。

本次评测配置将每轮新增额度设为 3500，按照实际模型投影的 token 估计计数，不把未发送的审计字段计入额度基数。全部历史还受整体有效输入预算约束：

$$B_{\text{input}} = 32768 - 8192 - 2048 = 22528,$$

分别为操作窗口、输出预留与安全余量。单次新增节点上限不等于整个历史的节点上限；必要时可重建上下文并重置交付集合。收尾时仅提供 Answer 工具并请求必选；普通文本仍由既有兼容路径接收，因此该设置不是严格的原生工具输出保证。

4 Evaluation

4.1 数据、模型与评测范围

实验来自 M3-Bench[3] 的 robot 子集：原五个开发视频之外，从剩余视频中以 seed=42 随机抽取五个扩展视频，预先固定十视频、128 题。主分析沿用执行顺序中的前八视频，共 97 题，包含五个扩展视频和三个原开发视频。两方法在这些视频上完成记忆构建及整套 QA 执行；`kitchen_01` 的两道原始超时题仍计零，不以之后重跑的答案替换，也不删除该视频。`study_18` 的 M3 路径出现 11 道连接失败，`kitchen_20` 因上游 embedding 失败未完成两方法问答，故不进入主配对子集。完整 128 题仍保留失败计零的记录：oGMemory 和 M3 均分分别为 0.4805 和 0.3320，有效回答为 109/128 和 100/128；该总体差异受到服务故障影响，不作为主要算法质量结论。

两方法共享本轮新生成的基础帧、完整音频及转写，分别独立生成记忆和执行 QA。记忆生成、QA 与评委均配置 MiniMax-M3.1-Flash，`thinking=adaptive`、`reasoning_effort=medium`；QA 输出上限 8192、评委 2048，最多 6 轮及 180 秒软预算。oGMemory 使用来源事实索引与严格增量 3500 配置；M3-Agent 保留参考 Action 文本控制协议，以共同模型替代专用训练权重。双方基础模型帧最多 16 张，M3 可额外输入至多 8 张人脸裁剪。本轮逐视频执行，两方法记忆生成均为 4 并发，QA 均串行。

本节对应已完成实验冻结版本`8d61b772`，使用全片段采样。后续人物绑定和并发版本的复测尚未形成完整对照，不与本节混合。所有分数统一取最终十视频共同评委批次：256 个方法–问题对按 seed=1102 交错，评委不接收方法名，无评委错误。每题 $s_i \in \{0, 0.5, 1\}$，主指标为 $S = \frac{1}{97}\sum_{i=1}^{97} s_i$，另列全分题比例和有效回答数。这是**自动评分，而非人工准确率**；不混用早期八视频临时评分。

4.2 同模型质量对比

表2与图1展示全部八个视频。oGMemory 题目加权均分为 0.5722，M3-Agent 为 0.4381，分差为 0.1340；oGMemory 在六个视频上更高，在`gym_03` 上持平，在`kitchen_23` 上较低。因而总分优势不是逐视频全面占优。有效回答分别为 95/97 和 97/97；覆盖率、自动评分与事实正确性应分开解释。

表 2: 已完成配对子集的逐视频自动评分。保留全部 97 题；失败计零。

视频	题数	oGMemory	M3-Agent	分差
study_09	12	0.5833	0.5000	+0.0833
kitchen_01	13	0.3846	0.1923	+0.1923
bedroom_05	12	0.4167	0.3750	+0.0417
study_23	14	0.6786	0.3214	+0.3571
kitchen_23	12	0.5417	0.6250	-0.0833
study_05	12	0.4583	0.3750	+0.0833
gym_03	11	0.7273	0.7273	+0.0000
bedroom_04	11	0.8182	0.4545	+0.3636
题目加权合计	97	0.5722	0.4381	+0.1340

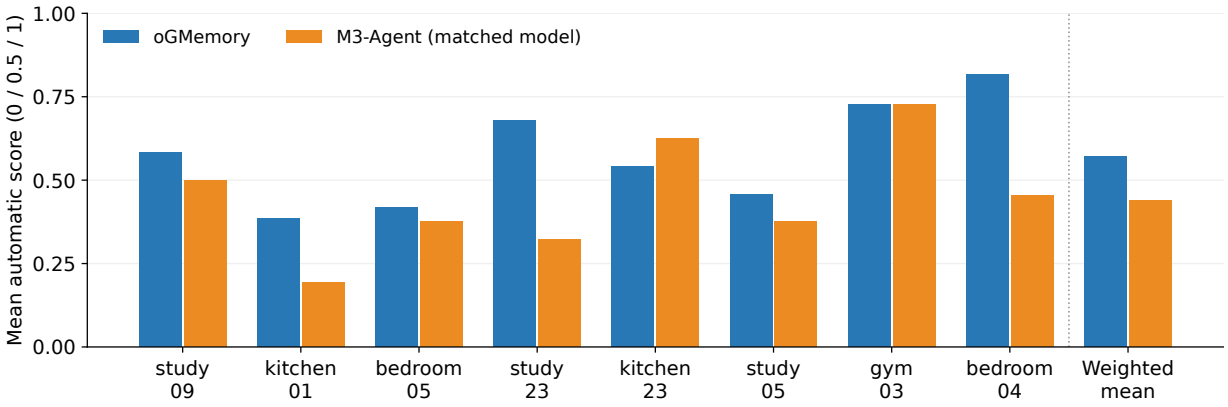


图 1: 两方法逐视频表现及题目加权均值。纵轴为自动评分而非人工准确率；不拼接早期临时评分或重跑答案。

表 3: 同一八视频子集的质量与资源开销。M 为百万 token，时间单位为分钟。

指标	oGMemory	M3-Agent
有效回答	95/97	97/97
全分题比例（%）	51.55	37.11
QA 输入（M）	4.039	0.734
其中未缓存输入（M）	2.129	0.263
QA 输出，含推理（M）	0.112	0.045
已记录建忆 +QA 总 token（M）	7.446	4.399*
共享感知与启动	49.02	49.02
记忆、图谱及索引	573.46	249.64
QA 耗时	65.91	31.02
各自计入感知后的总时间	688.39	329.68

*M3 建忆有 1 次失败请求未返回 usage，该总量仅表示已记录用量，不把未知值当作零；两方法 QA 用量完整。

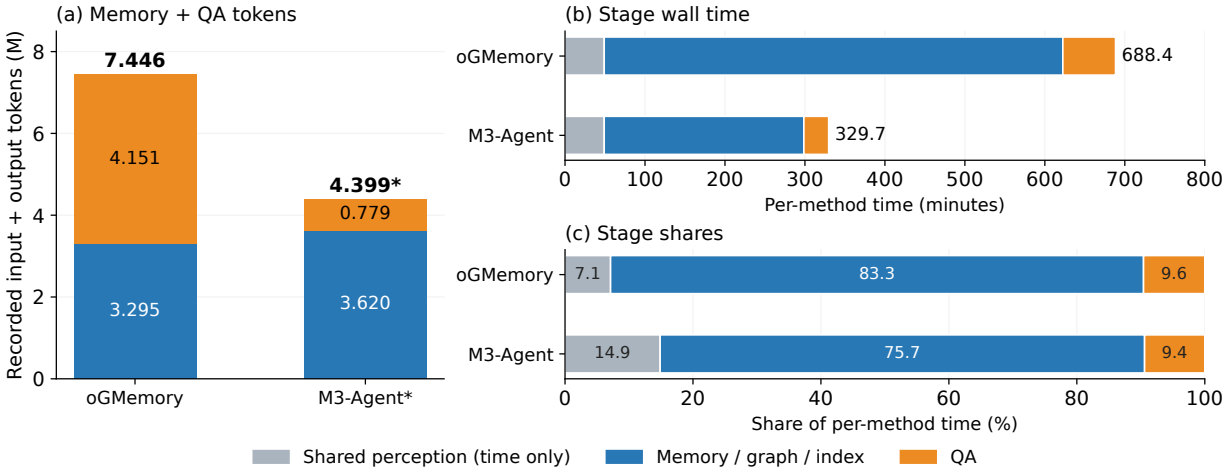


图 2: 资源开销及阶段分布。左图为建忆与 QA 已记录的输入、输出总 token，不含 embedding 和评委；星号表示 M3 有未知建忆用量。右图将同一次共享感知分别计入两条方法路径；占比由累计耗时计算，不能将两方法总时间相加当作实验墙钟时间。

4.3 Token 开销与阶段耗时

表3及图2使用同一 97 题集合。QA 用量覆盖所有调用，输入包含缓存部分，输出包含推理 token，不重复计数；建忆与 QA 合计不包含 embedding 及最终评委。M3 建忆有一次失败调用未返回 usage，图中星号总量仅为已记录值，未知部分未估算为零。

oGMemory 的 QA 输入为 4.039M，M3 为 0.734M，前者约为后者的 5.50 倍；未缓存输入分别为 2.129M 和 0.263M。oGMemory 保留丰富的来源证据，但当前结果仍表现为**更高自动评分与更高问答输入开销的折中**，不能据此宣称比 M3 更省 token。输入比例也不等于实际账单费用比例。

两方法分别计入同一份共享感知后，处理时间为 688.39 与 329.68 分钟。耗时统计采用阶段墙钟边界，包含初始化、等待与重试，不含最终评委及阶段间调度空隙。共享感知实际只执行一次，分摊到各方法用于独立路径比较，不能重复相加为实验总时长。记忆、图谱与索引占两方法各自耗时的 83.3% 和 75.7%，均为主要开销。oGMemory 该阶段中，旧实现重复处理账号累计人脸耗时 309.29 分钟，约占其总时间的 44.9%；因此这些时间反映所测实现，而非单个独立视频的固有建忆成本。M3 建忆封装了身份组织、生成与 embedding，不能可靠地进一步拆成纯模型计算时间。

4.4 解释边界

主子集不是独立留出测试，也不是对所有服务故障免疫的完整十视频对照。每方法仅一条完整配对轨迹，未据此宣称统计显著或稳定泛化增益。共同模型与共享感知改善了可比性，但两者的身份裁剪、记忆组织及控制协议仍不同：M3 末轮允许合理猜测，oGMemory 强调证据不足时说明。此外，`current_clip` 允许使用问题所在片段末尾的证据，不等于严格因果在线问答。分差不能单独归因于存储结构、某个算子或人物身份推理。

5 Conclusion and Discussion

本文从零构建 oGMemory-m3，以新增记忆图谱存储、算子机制与声明式编排，贯通媒体感知、情景抽取、来源关联、混合检索及多轮问答。在最新已完成实验的八视频配对子集上，oGMemory 相对同模型 M3-Agent 参考适配取得更高的自动评分，并以来源位置保存可检查的证据；与此同时，问答 token 与处理时间仍更高。质量、输入开销和阶段成本应联合报告，不能只用单一平均分评价系统。

全片段均匀采样改善了时间覆盖，但稀疏帧、ASR 误差、人物归属和事件计数仍可能限制记忆质量，检索不能补回未被感知的事实。阶段耗时揭示了身份处理与建忆环节的优化空间；后续人物关联和并发实现需要在同一完整题集上重新评测，不能将其预期收益归入本文已有结果。进一步应扩展独立视频样本，引入人工抽查或独立评委，并通过受控消融区分各算子的贡献。

记忆图谱也是面向文本记忆的共享存储设计。未来可将对话或文档作为源节点，将文本抽取事实和已有记忆映射到图谱，补建来源与支持关系，逐步迁移文本记忆。该迁移仍需验证历史来源、时间映射和检索兼容性，本次评测不声称已验证文本迁移收益。

参考文献

[1] Enxin Song, Wenhao Chai, Guanhong Wang, et al. MovieChat: From Dense Token to Sparse Memory for Long Video Understanding. *CVPR*, 2024. arXiv:2307.16449.

[2] Yue Fan, Xiaojian Ma, Rujie Wu, et al. VideoAgent: A Memory-augmented Multimodal Agent for Video Understanding. *ECCV*, 2024. arXiv:2403.11481.

[3] Lin Long, Yichen He, Wentao Ye, et al. Seeing, Listening, Remembering, and Reasoning: A Multimodal Agent with Long-Term Memory. arXiv:2508.09736, 2025.

[4] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, et al. Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442, 2023.

[5] Charles Packer, Sarah Wooders, Kevin Lin, et al. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560, 2023.

[6] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, Deshraj Yadav. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv:2504.19413, 2025.

[7] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, Yongfeng Zhang. A-MEM: Agentic Memory for LLM Agents. *NeurIPS*, 2025. arXiv:2502.12110.