oGMemory：面向长视频问答的多模态记忆系统架构设计与实验评估

oGMemory / memory-eval

2026 年 11 月 2 日

摘要

长视频问答要求将分散的视觉、语音与人物线索转化为可长期保存、按需检索的证据。本文面向原本不具备多模态记忆能力的 oGMemory，设计并实现从媒体感知、情景记忆构建、来源关联与索引到多轮检索问答的完整多模态记忆系统。系统以统一来源组织连接视频片段、结构化事实与回答证据，通过片段与事实的混合召回保留局部细节，并以来源位置去重和有界增量交付控制重复上下文。在 M3-Bench 固定五视频、65 题的固定记忆 QA 评估中，使用相同 MiniMax-M3.1-Flash 模型与共同自动评委，oGMemory 来源事实组合两次运行均分为 0.5962，高于 M3-Agent 参考适配的 0.4615；严格增量方案获得 0.5846，65 题均有效回答，相较本系统同期有界上下文基线减少 38.2% 的 QA 输入和 63.6% 的未缓存输入。结果展示了来源可追溯、细粒度证据检索和受控上下文交付相结合的应用价值。

1 Introduction

多模态记忆的目标并非保存尽可能多的原始媒体，而是在有限计算和上下文预算下，为后续问题保留可定位、可关联的证据。长视频中的回答可能依赖多个时刻的物品变化、人物偏好、对话内容与视觉状态。直接将全部视频描述和转写拼接给语言模型，会使无关信息和重复检索结果累积；过早压缩成短摘要，又可能丢失姓名、数量、动作对象等决定答案的细节。

构建这样的记忆系统需要贯通三个环节。首先，**多模态感知与记忆表示**需要把视频帧、语音转写、人物与事件组织到共同的片段和时间坐标中，使不同模态的观察能够联合使用。其次，**证据组织与检索**需要兼顾片段背景和局部细节，既能回答某个时刻发生了什么，也能定位分散在多段对话或画面中的相关事实。最后，**按需交付与问答**需要将检索结果转化为语言模型可消费的有界上下文，避免反复发送相同内容，同时允许继续补充证据。

原有 oGMemory 不具备多模态记忆能力。本文以其通用记忆基础设施为承载，从头设计并实现多模态记忆子系统：接入视频与音频，生成结构化情景记忆，建立来源关系及多粒度索引，再通过带时间约束的检索与多轮问答使用这些记忆。本文的工作范围覆盖整条多模态处理链路，而非对一个预先存在的多模态记忆模块进行局部优化。核心设计包括：

- **来源贯通的记忆架构**。将媒体、抽取结果和记忆关联存储，保留片段时间及证据出处，使记忆可检查、检索可回源、片段失败可定位。
- **兼顾背景与细节的检索**。联合情景片段、转写和原文事实窗口，结合有来源的人物条件，使局部证据能够在保留片段背景的同时进入问答。

- **受控的证据消费**。以已交付的来源位置为粒度增量补充证据，结合整体输入预算与回答收尾机制，降低多轮检索中的重复输入。

我们在 M3-Bench 的五个视频上构建并使用该系统，并以相同模型适配的 M3-Agent 作为对照。实验部分固定已生成的记忆，比较系统内部不同检索和交付配置，报告共同自动评分与 QA 输入。这一评估用于检验问答阶段的设计取舍；系统完整架构与本轮实验测量范围分别说明。

2 Related Work

2.1 片段检索与结构化多模态记忆

从系统设计看，长视频记忆可以采用片段描述检索，也可以进一步组织为事件、人物、实体关系及语义结论。前者保留局部上下文、便于回源，代价是检索结果冗长；后者有利于紧凑交付和跨片段关联，但依赖抽取与身份绑定的可靠性。本文关注这两类设计之间的折中：事实窗口仍来自已有原文，不以额外生成的摘要替代来源；检索粒度细化后，仍回到源节点校验时间、权限与内容一致性。

2.2 M3-Agent：身份锚点、分层事实与控制器

本地 M3-Agent 参考实现 [1] 以人脸和声音作为持久锚点，将视觉与带说话人标记的转写共同用于生成短情景事实和高层语义结论。它显式表达脸–声等价关系，并归并为人物标识，支持姓名或人物标识解析后的实体条件检索。因此，身份线索参与记忆生成和检索，而不只是与文本并列保存的特征。

其普通控制路径每次主要返回 top-2 片段，并记录已经交付的片段，只追加新的片段；人物标识查询另有按记忆条目检索的路径。该机制并非无限制的多跳图遍历。参考控制器采用 Action 文本协议，末轮允许合理猜测。本研究保留这一参考控制思路，但以共同模型适配替代专用记忆和控制权重，因此报告的是**同模型参考适配结果**，不是官方 checkpoint 或论文成绩复现。

2.3 与本文设计的区别

M3-Agent 强调生成阶段的紧凑事实、语义结论和持久身份关联；本文为 oGMemory 构建的多模态子系统按原始数据（Raw）、抽取结果（Extracted）与记忆（Memory）组织来源，并在默认 QA 路径检索情景节点。本文新增的来源事实索引不是完整的 M3-Agent 语义层：它不生成额外推断，而是将原文单位变成可召回的证据。人物条件也仅利用已有姓名/角色声明，未形成已验证的人脸–声音–姓名链接。在交付上，M3-Agent 主要按片段避免重复；本文按源位置去重，允许后续查询继续补充同一片段中尚未看到的事实。两者的设计取舍是：更强的紧凑性与身份结构，对比更细粒度的回源能力和增量证据覆盖。

3 Method

3.1 总体架构与数据流

系统建立“媒体接入与感知、记忆构建与存储、索引与检索、上下文交付与回答”四层处理链路。通用存储与算子机制由 oGMemory 承载，视频/音频处理、情景记忆生成、多模态来源关联、

面向视频的索引检索及问答控制均属于本文新增的多模态能力。离线构建层把连续媒体转化为持久记忆；在线问答层根据问题和时间范围选择证据，无需在每次回答时重新处理完整视频。表1概括模块职责。

表 1: oGMemory 多模态记忆子系统的层次与数据流。

层次	主要处理	输出与接口
媒体感知	视频切片、帧与音频提取、转写、人物线索	带片段及时间来源的媒体与观察
记忆构建	多模态情景抽取、来源关联、视频级整合	片段描述、人物、事件、实体及支持关系
索引检索	片段/事实向量、转写召回、人物软排序	经账号、视频、时间与哈希校验的证据
检索问答	Search/Answer 循环、增量交付、预算控制	可回溯证据的回答及运行记录

3.2 媒体感知与结构化情景抽取

视频按 30 秒切片，每段创建视频源节点，并关联抽取的图像帧及 16 kHz 单声道音频。视觉处理提取帧及人脸线索；音频处理使用 Whisper 转写、pyannote 说话人分离及 ECAPA 声纹特征。图像、可用音频和转写进入情景记忆生成算子，形成包含 description、characters、events 和 entities 的片段级结构化输出，分别记录场景描述、人物、事件及实体。这一表示将视觉观察与对话内容置于同一片段背景下，为后续文本化检索提供统一入口。当前帧采样为 1 fps 取前至多 16 帧，其覆盖限制在讨论中说明。

片段处理保留独立状态和失败清单。无效结构化输出可有限重试，仍失败的片段被显式记录；继续处理其他片段后按覆盖门槛判断整体是否合格，避免单片段故障直接中断全部视频，也不把缺失片段伪装成完整记忆。

3.3 来源存储、人物线索与时间约束

原始媒体作为 Raw 节点，结构化抽取作为 Extracted 节点，持久记忆作为 Memory 节点，三者通过来源及支持关系连接。问答默认检索情景抽取节点，并可由节点及字段位置返回原片段。视频级记忆通过描述拼接和集合去重整合，维护支持与演化关系；它不额外生成高层语义推断。人脸和声音聚类保留人物关联线索，但这不等于已核实的跨模态姓名绑定，也不意味着默认 QA 直接遍历所有身份关系。

所有检索受账号、视频和可用时间限制。本文实验采用`current_clip` 协议，允许使用问题所在片段末尾之前的证据；事实可用时间保守地取其来源片段末尾，不读取未来片段建立姓名映射。由于该边界可能晚于问题时刻，本文不将这一设置称为严格因果在线问答。

3.4 来源事实索引与混合召回

我们将源记忆拆成三类窗口：description 的局部原文、相邻三条 ASR 转写，以及完整的事件、人物或实体项。每个窗口记录源节点、字段位置或字符范围、内容哈希及可用时间。相同文本在不同时间出现仍是不同观察；窗口数不能直接当作事件发生次数。

在五视频上，7,965 个窗口由 BGE-M3 编码为 1024 维向量。检索层并行使用片段向量、转写

和事实窗口召回；事实命中按最大分数聚合到源节点，再与片段及转写候选排序等权融合：

$$\mathrm{RRF}(d) = \sum_{r \in \mathcal{R}} \frac{1}{k + \mathrm{rank}_r(d)}.$$

其中 $\mathcal{R}$ 表示参与融合的排序，k 为平滑常数。候选进入上下文前需再次验证范围与源内容哈希，避免旁路索引绕过权限或引用过期内容。该索引是面向小规模固定数据的密集检索原型，而非生产级 ANN 或动态语义图。

3.5 显式人物条件软排序

在已通过范围过滤的候选内，查询若完整匹配来源中的 name 或 role，则给予有限的排序奖励，并提高对应人物描述的准入优先级。我们不硬性排除无匹配候选，避免将“没有写姓名”误当成“不属于此人”。局部 `SPEAKER_00` 等标签不作为跨片段身份，角色相同也不自动合并人物。这是一种来源声明驱动的检索条件，而不是身份识别算法。

3.6 严格增量证据交付与回答收尾

每题维护已实际发送的来源位置集合 D_t。第 t 轮检索的候选事实为 C_t，只从 $C_t \setminus D_t$ 中选入新证据；过去的工具消息保持不变。这种去重既减少整片段重传，也允许补充同源片段的不同事实。停搜依据实际新增可见事实，而非仅检查是否出现新节点。

严格增量方案 E 将每轮新增额度设为 3500，按照实际模型投影的 token 估计计数，不把未发送的审计字段计入额度基数。全部历史还受整体有效输入预算约束：

$$B_{\mathrm{input}} = 32768 - 8192 - 2048 = 22528,$$

分别为操作窗口、输出预留与安全余量。单次新增节点上限不等于整个历史的节点上限；必要时可重建上下文并重置交付集合，本轮 E 未触发重建。收尾时仅提供 Answer 工具并请求必选；普通文本仍由既有兼容路径接收，因此该设置不是严格的原生工具输出保证。

4 Evaluation

4.1 数据、设置与指标

固定 M3-Bench robot 子集的五视频（原抽样 seed=42），共 65 题，视频不按成绩替换。记忆生成、QA 与自动评委均配置 MiniMax-M3.1-Flash，`thinking=adaptive`、`reasoning_effort=medium`；QA 输出预算 8192，评委 2048，最多 6 轮及 180 秒软循环预算。软预算不等于单请求或端到端硬超时。此次比较固定各自已生成的记忆，M3-Agent 使用独立生成的 340 片段记忆，而非借用 oGMemory 记忆。

最终共同评分覆盖 11 条完整轨迹的 715 条答案，按 seed=1102 交错安排，评委不接收方案名。每题评分 $s_i \in \{0, 0.5, 1\}$，主指标为 $S = \frac{1}{65}\sum_{i=1}^{65} s_i$；无效答案计零，并单列有效率。所有评分完成，无评委错误。这是**自动评分均值，而非人工准确率**。重复运行不增加独立题目数；主表只用本批共同评分，不拼接历史较高分数。QA 输入统计覆盖全部题目及多轮调用，含缓存输入，并另列未缓存部分；不包含感知、历史记忆生成或评委调用。

4.2 同模型主结果

B 为本文多模态子系统的有界上下文基线，而非新增多模态能力之前的 oGMemory；S 组合来源事实索引、人物条件与修正的增量交付；E 进一步使用严格 3500 新增额度和收尾请求。表2同时保留 B 的历史固定轨迹与同期重复，避免仅选较弱基线。两次运行行的 token 数为每次运行的平均，非两次总和。

表 2: 五视频共同评分与 QA 输入。M 表示百万 token；括号为重复次数。

方案	均分	有效回答	输入 (M)	未缓存 (M)
M3-Agent 参考适配（2）	0.4615	65/65	0.561	0.194
B 历史固定轨迹（2）	0.5962	65/65	4.756	4.138
B 同期重复（1）	0.5308	65/65	4.721	4.137
S 来源事实组合（2）	0.5962	65/65	3.433	2.081
E 严格增量（1）	0.5846	65/65	2.916	1.508

S 两次得分分别为 0.5846 与 0.6077，均值恰好等于 B 两条历史答案的本批重评分均值。同期 B 仅 0.5308，显示运行波动不可忽略。E 相对同期 B 的总输入减少 38.2%，未缓存输入减少 63.6%；相对 S 两次平均进一步减少 15.1% 和 27.5%。因此主要证据是**保持此前质量附近的输入效率改善**，不是已确认的无损压缩或稳定提分。E 只有一次运行，独立重复因额度低于预设启动门槛未执行。

相对 M3-Agent 两次均值，S 和 E 分别高 0.1346 和 0.1231，但 E 的总输入仍为其 5.20 倍，未缓存输入为 7.77 倍。M3-Agent 的紧凑事实和少量片段交付仍有明显输入效率优势。这些 token 比例不能直接解释为费用或墙钟加速比。

4.3 分视频表现与消融

表3显示收益并非所有视频一致。E 在 study_18 和 kitchen_20 上高于同期 B 及 M3-Agent，但在 gym_03 上低于 B；study_18 绝对得分仍较低。M3-Agent 与 E 在 study_05、gym_03 上相同，不能将总分差解释为全面能力优势。

表 3: 分视频自动评分。S 和 M3 为两次均值，B 为同期运行。

视频	题数	B	S	E	M3
study_05	12	0.4167	0.4583	0.4583	0.4583
gym_03	11	0.6818	0.6591	0.6364	0.6364
bedroom_04	11	0.7273	0.7955	0.7727	0.6364
study_18	14	0.3214	0.4286	0.4643	0.2679
kitchen_20	17	0.5588	0.6618	0.6176	0.3971

早期消融中，仅原文事实窗口 F 为 0.5000，增加姓名/角色条件 FI 为 0.4923，再加入初版增量交付 FIP 为 0.5462（64/65 有效，唯一协议失败计零）。这说明切短文本或显式人物条件本身不保证整体收益；S 包含多个组合变化，不能把其全部增益单独归于事实向量索引。数据集题型为重叠多标签，多跳推理仅 1 题，不据此判断泛化能力。

E 的 370 次 QA 调用中未发生上下文重建，305 次相邻消息前缀检查全部保持；该检查不含工具 schema，也不保证供应商缓存命中。57 次 Answer-only 请求中 41 次返回原生工具，16 次普

通文本由兼容路径接受；45 秒回答预留没有实际触发，不能把本轮效果归因于该预留。来源位置审计未发现时间越界或重复交付，但来源一致不代表事实或答案必然正确。

4.4 公平性与复现边界

相同模型并不等于严格单因素对照。M3-Agent 参考适配采用 Action 文本协议和末轮猜测，oGMemory 采用原生工具并强调证据不足时说明；参考方未加载专用训练权重。感知替换、BGE 嵌入适配和身份裁剪也构成差异：两边基础帧/WAV 相同，但 M3 额外使用至多 8 张身份人脸裁剪，study_18 的一个片段存在 4 处 ASR/时序差异。故分数差不能纯粹归因于存储结构、身份图或检索算法。

共同评委虽完成 715 条评分，但 714 个需模型评分任务的 usage 及逐响应模型标识未持久化（另 1 条无效答案自动计零）；配置与冻结代码可核查，历史响应 trace 无法恢复。全部 QA 用量记录完整，表中 QA 比较有效，**整轮总 token 和总费用不能完整报告**。详细逐题结果、配置与审计保留于实验记录 [2]，未以估算补账或重评替代原结果。

5 Conclusion and Discussion

本文为原本不具备多模态记忆能力的 oGMemory 构建了完整的多模态记忆子系统，贯通媒体感知、情景抽取、来源关联、混合检索与多轮问答。系统以可回源的记忆组织保留证据，以细粒度检索和增量交付控制问答上下文。在固定五视频上，来源事实组合达到与历史有界基线接近的自动评分，严格增量方案进一步降低输入。相同模型下，其得分高于 M3-Agent 参考适配，但输入仍显著更多。当前更合理的结论是质量–输入开销的折中改善，而不是已解决多模态身份或实现稳定全面提分。

限制包括五视频开发集、同模型自动评委、E 尚无重复，以及本轮仅评估固定记忆的 QA 路径。视觉前缀采样、ASR 错误和错误人物归属仍会限制检索；新增来源索引无法恢复未被感知的事实。此外，`current_clip` 不满足严格因果协议，重复试验也不能代替独立留出测试。

下一步应优先完成 E 独立重复与新视频验证，并用独立评委和人工抽查核验主要差异；在生成阶段引入可撤销、带时间来源的脸–声–姓名关联，单独测量身份错误；最后在统一感知和控制协议下重跑端到端实验，同时补齐用量采集。完整历史实验日志保留在仓库中，不作为本文主体展开。

参考文献

[1] M3-Agent 参考代码（本地快照）. `m3-agent/`, commit `0e3e41939bd8a0b66d756e7b7eb8d5fe9992da5c`. 重点审阅 `m3_agent/control.py`、`mmagent/retrieve.py` 和 `mmagent/videograph.py`；源码对照说明见 `docs/m3_agent_comparison.md`.

[2] oGMemory / memory-eval 实验记录. `experiments/m3_memory_design_20261102/`, 2026-11-02. 最终共同评分见 `comparison.json` 和 `joint_questions.csv`；方法说明见 `docs/m3_memory_design.md`.