oGMemory 多模态记忆与检索优化评估
M3-Bench 五视频对照实验

memory-eval 工作区实验记录

2026 年 11 月 2 日

摘要

本报告对 oGMemory dev 分支的多模态记忆与问答流程进行代码审计，并在 M3-Bench robot 子集固定抽取五个完整视频、共 65 题开展实际实验。评估同时关注媒体覆盖、记忆生成、检索与问答、自动评分及执行可靠性。原始默认配置、环境修复和后续恢复严格区分；不以历史答案代替本次运行，不以缺题后的成功子集均分代替端到端表现。当前结果属于小规模开发性诊断，不是完整数据集成绩，也不是独立人工验证的准确率。本报告保留首轮失败、定向恢复和共同重评三个阶段；首轮同模型对照见第 8 节，不将不同阶段的较高分数择优拼接。后续固定记忆的上下文预算、收尾控制、紧预算与分组表示消融见第 9 节，运行中与最终共同评分明确区分。用量分析同时区分缓存和未缓存输入，不将总 token 缩减直接解释为费用缩减。 11 月 2 日进一步评估来源事实索引、人物词条件和增量交付，见第 10 节。主要可确认收益是 QA 输入效率，稳定提分与身份绑定仍需验证；共同评委用量漏采单列说明，QA 用量记录完整。

1 目标与可追溯性

主要评估对象是当前目录的 `oGMemory/`，未开展新的 LoCoMo 实验。首轮基线源码分支为 dev，固定提交为 `8c86c3ed`（完整哈希见实验目录 `provenance.json`）。首轮不修改记忆与检索算法，为 M3 配置工厂和 MiniMax 适配器补充可选推理参数透传，并加入默认关闭、最多 4 个独立片段并发的吞吐优化；固定提交加补丁构成实际运行版本。新增脚本、脱敏配置、逐题结果和报告均置于外层 memory-eval 工作区。模型、数据库、配置与抽样清单分别记录，凭据和大型原始媒体不纳入外层 Git 仓库。后续可靠性与上下文改动在 `m3_dev_1031` 分支提交；每组实际运行的源码提交与归档哈希以对应 `manifest.json` 为准，不能用当前 HEAD 替代历史冻结版本。

2 当前方法

2.1 输入与多模态证据

完整管线定义于 `config/m3/pipelines/video_episodic_full.yaml`，包括 18 个阶段。视频按 30 秒切片，建立 VIDEO RawNode；画面与音频作为带来源关系的子节点。音频为 16 kHz 单声道，Whisper large-v3-turbo 产生带时间标记的英语转写；pyannote 分离说话人，SpeechBrain ECAPA 产生声纹特征，HTTP CV 服务处理人脸。

画面按 1 fps 取至多 16 帧，缩放参数为 512，JPEG 质量参数为 80。**默认帧主要来自片段前约 0–15 秒，而非覆盖全片段的均匀采样**。因而“完整视频实验”只表示处理全部片段与完整音频，不能解释为视觉观察无遗漏。

2.2 情景记忆与图组织

`m3/episodic_memory.py` 将画面、可用原始音频和 ASR 转写交给多模态情景记忆算子，生成 description、characters、events、entities，并存为片段对应的 ExtractedNode。后续创建具有支持来源的 MemoryNode；人脸与声音聚类产生身份关联，语义整合阶段生成视频级聚合 MemoryNode。

视频级整合是确定性的描述拼接与集合去重，描述上限为 50,000 UTF-8 字节，并同步 SUPPORTS / EVOLVES 关系；不是新的大模型抽象推理过程，也不自动保证事实冲突消解、事件去重计数或长期状态一致性。被截断的多模态输出明确记为失败，不能通过补齐 JSON 括号冒充有效记忆。

2.3 索引、检索与回答

结构化记忆和原始 ASR 转写展开为文本，使用 BGE-M3 1024 维嵌入，写入 SQL 图及向量索引。默认 Search 检索 `episodic_memory_generator` 类型的 ExtractedNode：原始查询向量召回，必要时追加去人名查询，结合转写 BM25 重排及独立 transcript 词法召回，经 RRF 融合后补充邻近片段和时间边界转写。

生成身份图和语义汇总不等于默认问答直接检索了这些图结构。本次不能据管线执行完整就宣称图关系或视频级语义汇总提高了答案质量；这需要独立消融与实际证据路径审计。

ReAct 问答通过 Search / Answer 工具运行，最多 6 轮，循环预算 180 秒。默认主检索 top-k=8，向量候选 20，转写候选 20，邻居半径 1，邻居上下文最多 8 条。未启用可选 `m3.qa_context`：默认 top-k 不是模型不可突破的服务端上限，不同查询的重叠内容仍可能累积。单次请求 timeout=300 秒与 SDK 重试也意味着 180 秒不是端到端硬时限。

2.4 时间与权限边界

检索限制在当前账号和视频范围。问题 timestamp 优先于原始 before_clip 编号，并根据实际片段来源区间定位。本次采用 `current_clip`，证据截止时间扩展到问题所在片段末尾，可能包含问题之后的少量内容。因此该协议**不是严格因果在线问答**；实际宽限由每题 `temporal_scope` 记录。后续严格时间策略应单独对比。

3 与 M3-Agent 的实现差异及对照评测设计

3.1 范围与实现路径

本节依据本地 `m3-agent/` 的固定提交 `0e3e419` 做静态代码审计，不是新增 M3-Agent 跑分。其 robot 标注与本次数据副本的规范化 JSON 哈希一致，五视频 65 题逐项匹配；记录见 `docs/m3_agent_review.json`。该静态审计阶段未加载参考模型权重、未反序列化 pickle 图、未调用参考模型 API，也未运行可能改变现有 GPU 环境的参考安装脚本。后续实际完成的同模型适配评测见第8节，不能将静态审计阶段的状态误读为后续没有运行对照。

参考实现分为感知中间产物、记忆图生成和控制问答三个入口。每个视频维护一个 `VideoGraph`，包含 img（人脸）、voice、episodic 和 semantic 节点及双向加权边，最后保存为 pickle。感知侧使用 InsightFace，以及代码中声明的 Gemini 对话分段和 ERes2NetV2 声纹。这不同于本轮 Whisper、pyannote、ECAPA 的组合。

记忆生成把视频、带 face ID 的人脸裁剪、带 voice ID 和时间戳的转写一起交给专门的 memorization 模型。输出既包含原子事件，也包含人物意图、关系、身份等高层结论，以及显式的人脸–声音等价事实。语义事实按向量相似度强化或弱化相关边；身份等价关系通过并查集建立 `character_N` 映射。这里的相似度规则不是经过验证的逻辑矛盾消解器。

控制器被提示先寻找名字与 character ID 的对应关系，再用 ID 查询。检索可按身份关联限制情景/语义文本候选，做向量匹配和片段级聚合，返回选中片段中的记忆，并避免重复返回已见片段。默认控制入口使用专门的 Control 权重、五轮文本 Search/Answer 动作，最后一轮要求回答且允许猜测。参考默认控制路径和本轮 oGMemory QA 都主要读取文本记忆，并不在每题重新读取原始画面。

3.2 关键差别：身份和语义记忆是否进入问答路径

维度	M3-Agent 参考路径	本次 oGMemory 路径
记忆组织	实体中心的单视频多模态图	Raw–Extracted–Memory 来源层次与 SQL 图
身份信息	生成时注入 face/voice ID，检索时使用等价映射	生成身份关系，但默认 Search 未显式使用该映射
语义记忆	模型推断高层事实、身份等价与边权更新	按视频拼接描述、集合去重，描述上限 50 KB
默认召回	情景与语义文本；实体关联约束；片段聚合	情景 ExtractedNode、转写词法召回、RRF 与邻近片段
嵌入	text-embedding-3-large	BGE-M3，1024 维，本地 GPU
控制	专门权重，5 轮，最后允许猜测	MiniMax 原生工具，6 轮，180 秒循环预算
存储与审计	VideoGraph、每视频 pickle	SQL/向量索引、账号/视频过滤、阶段回执与实验审计
默认评分	GPT-4o 二值 Yes/No	MiniMax 的 0/0.5/1 参考均分

oGMemory 不是简单把 M3-Agent 的图换成 SQL，也尚未完整复现其身份驱动的语义记忆问答机制。本轮更明确的优势方向是持久化、来源可追溯、失败处理和转写增强检索；参考实现更直接地把身份等价与高层语义事实接入回答链路。二者都是实现差异，而非已经通过对照证明的质量胜负。oGMemory 也并非整管线原子事务；本实验用独立数据库规避旧片段 ID 的跨实验冲突。

3.3 不能直接比较现有分数的原因

1. **评分口径不同：**参考代码用二值 GPT-4o 评委，本轮是同模型分级评分。0.5 不能直接当作二值正确；建议对两组固定预测同时给出共同二值评分与共同分级评分。

2. **模型与预算不同：**专门训练的 memorization/control 权重、MiniMax、不同嵌入模型、轮数和输出预算会混淆架构归因。

3. **时间可见性不同：**参考控制入口读取 before_clip，本轮按 timestamp 使用 current_clip。以 30 秒零基切片作示意，study_05 首题在 03:45、before_clip=6，两种协议可能分别允许约 210 秒与 240 秒之前的证据。实际比较必须统一 source interval 截止条件。

4. **媒体输入不同：**参考预处理的 5 fps 不等于其模型最终看到固定帧数，模型的视频处理器还有自身采样。本轮是每片段前缀最多 16 帧；相同视频和切片长度不保证相同视觉覆盖、转写或人物特征。

5. **工作负载不同：**下载现成图后只跑控制器是 QA-only，不能将其耗时与包含感知及记忆重建的完整管线比较。

预构建全视频图还需审计一个静态风险：后续片段可能更新较早语义节点的边权及身份锚点，仅删除未来文本节点不必然恢复历史图状态。这不是已经测出的泄漏率；严格因果对照可使用前缀图快照。

3.4 建议的两条评测线

第一条是**参考系统复现**：固定同一 65 题，先用可信的参考图和官方 Control 权重建立单独标记的 QA-only 基线；再视需要重建参考记忆做端到端比较。保存原始协议成绩，并在共同评委、共同时间截止条件下另行比较。

第二条是**同模型架构消融**：统一生成/回答模型、嵌入、评委、帧/音频预算、可见时间、回答策略和计算预算，只比较实体/等价关系检索与片段/转写检索等结构差异。这种移植应称为 M3-Agent-style 或 adapted，而非官方权重成绩。top-k 也不能只对齐数值：两个片段的全部原子记忆不等于八个情景节点及其邻居。

复现前还应检查本地代码的接口不一致：README 数据示例使用 `intermediate_path`，而入口读取 `intermediate_outputs`；提示词给出单数 `video_description`，读取代码却取复数 `video_descriptions`；片段遍历未显式数字排序，而部分截断逻辑依赖插入顺序。这些是需要 smoke test 和独立补丁记录的问题，不代表论文报告的实验一定失败。完整源码锚点、对照矩阵与部署前置条件见 `docs/m3_agent_comparison.md`。

4 实验设置

原始 wrapper 配置写 `omni-3b`，本地实际提供 `omni-7b`。首次试运行纠正名称并使用独立数据库，遇到缺失 vector 扩展后完成环境修复。随后用户要求改用 MiniMax-M3.1-Flash，故于 17:56 停止小模型进程树，保留已生成的部分记忆和失败日志，**不将中断试运行视为完整基线成绩**。正式 MiniMax 实验使用新数据库并重新生成记忆，三类 LLM 均使用指定模型。由于模型和输出预算均变化，不能据此计算“仅换模型”的质量增益。首次 MiniMax/max 正式尝试的首片段也出现 8192 tokens 全部用于推理、没有正文。同一输入改用 medium 后输出 1451 tokens（推理 431），获得完整记忆。因此另建本次 adaptive/medium 正式实验，重新生成全部记忆，保留 max 尝试作诊断。这只是单片段可运行性证据，不是 medium 优于 max 的全数据集质量结论。可选并发默认值仍为 1；

项目	设置
数据	`/data/m3_data/annotations/robot.json` 与原始 robot 视频
抽样	100 个候选排序后 seed=42，无放回选取 5 个，不按成绩换样本
记忆 / QA / 评委	远端 `MiniMax-M3.1-Flash`，用户指定 API 端点
正式输出预算	记忆 8192，QA 8192，评委 2048 tokens
推理参数	thinking=adaptive，reasoning_effort=medium；不发送 temperature
运行方式	完整视频，SQL 图，强刷主要抽取环节，不导入历史记忆
隔离	专用数据库、账号与向量表；不覆盖历史实验
计算环境	本地 T4 服务；音频阶段使用物理 GPU 2；情景生成 4 workers

视频	时长（秒）	题数
`study_05`	2044.889	12
`gym_03`	2033.514	11
`bedroom_04`	1650.684	11
`study_18`	2498.519	14
`kitchen_20`	1887.527	17

本次设为 4，按清单顺序汇总结果，并保留逐片段失败。实际请求使用 `max_completion_tokens`，包括推理与最终输出；用户示例中的 500 tokens 只用于文本连通性测试。`study_05` 曾用于历史开发，所以本次不属于独立留出测试。

5 指标与失败处理

对于固定的 $N = 65$ 个问题，自动评委输出 $s_i \in \{0, 0.5, 1\}$。题目加权均分与视频宏平均分别为：

$$S_{\text{micro}} = \frac{1}{N}\sum_{i=1}^{N} s_i, \qquad S_{\text{macro}} = \frac{1}{5}\sum_{v=1}^{5}\frac{1}{N_v}\sum_{i\in v} s_i.$$

缺失答案与执行失败在端到端效用分中计零，同时单列缺失数、记忆覆盖和有效答案率。评委服务故障与模型答错分开：存在未评分的有效答案时，不将故障伪装成质量零分。题型采用数据集原始标签组合分组，不对多标签重复计数。

同一 MiniMax-M3.1-Flash 同时生成和评分，容易产生相关偏差；自动均分不是精确匹配准确率，也不是独立人工核验准确率。仅五个视频且题目在视频内相关，本报告不提供不恰当的独立题目置信区间，也不将单配置结果描述为相对于其他方法的因果提升。seed=42 只固定视频抽样；远端模型没有固定生成 seed，后端权重版本也不能由本地锁定。因此保存原始响应是可追溯性要求，不能保证再次运行逐字复现答案。

6 首轮固定配置运行结果

以下保留首轮原始统计；定向恢复和共同评委重评另列，不用后续结果覆盖首轮失败。管线结束状态为 `failed`。固定 65 题中保存 51 条 QA 记录，45 条答案非空且没有运行错误。题目加权自动均分为 **0.4692**，视频宏平均为 **0.4754**。评委错误 0 个。 分类表按原始标签分别计分，多标

视频	题数	有效答案	记忆/片段	索引	自动均分
study_05	12	9	69/69	69	0.2917
gym_03	11	10	68/68	68	0.7727
bedroom_04	11	9	56/56	56	0.6364
study_18	14	0	83/84	0	0.0000
kitchen_20	17	17	63/63	63	0.6765

标签	题数	有效答案	自动均分
Cross-Modal Reasoning	21	14	0.4286
General Knowledge Extraction	25	18	0.4200
Multi-Detail Reasoning	28	16	0.3393
Multi-Hop Reasoning	1	1	1.0000
Person Understanding	21	18	0.7381

签题重复进入多个分组；不能将分类题数相加作为总分母。总体均分仍严格按固定全集计算。SQL 审计发现悬空或跨账号关系 0 条。各视频的阶段状态、失败清单和向量覆盖见机器审计文件。用

环节	逻辑调用	输入 tokens	输出 tokens	推理 tokens
记忆	340	1587131	475023	147270
问答	241	14823188	72366	54743
评委/其他文本	45	28476	3423	1375

量来自实际收到的 API usage，不等于账单金额。逻辑调用耗时包含网络、排队、推理与 SDK 重试，并发请求耗时和不等于整轮墙钟时间。预检与前序中断尝试另行保存，不混入本表。

6.1 首视频逐题审计与局限

2026 年 10 月 31 日 20:09 对 study_05 单独完成了一次临时评分：12 题中 9 题有效回答、3 题循环超时；2 题满分、4 题半分、6 题零分，均分 0.3333，评委错误为 0。正式五视频统一评分另行执行，不取两次评判中的较高者；故本节临时分与最终总表可能因评委波动而不同。本节只审计首视频的预测、金标和调用记录，不是五视频完整错误分布，也没有通过观看全部原视频独立核验金标。

- 彩纸回答在桌面，金标为最右书柜顶层抽屉；可能混淆原始存放与使用位置。
- 树的总数回答 2，金标为 1，回答将 “再做一棵” 的计划用作完成依据。
- 树干步骤回答 3，与金标一致，但引用理由仍需核实，不能仅凭数值匹配证明推理过程正确。
- 书包回答桌面，金标为桌子左侧，却获临时半分；说明自动评委可能偏宽。
- 装饰物答纸苹果，金标是黏土苹果，对象类别部分正确但材质错误。
- 叶子步骤、是否只关心学习和剪刀次数三题循环超时，没有有效答案；它们不是评委故障。

首视频 QA 记录了 60 次逻辑模型调用、累计 3,994,009 输入 tokens，单次输入峰值 147,951 tokens。长上下文与循环超时并存，支持优先检查检索证据累积和迭代效率；但没有严格消融，不能认定所有超时均由上下文大小导致。下一步可冻结同一份记忆，仅切换已有有界上下文机制，分别比较答案质量、覆盖、输入量与耗时。

6.2 另两视频的补充审计

23:10 的临时评分中，gym_03 为 8 题满分、3 题零分，均分 0.7273；其中一题超时，另两题分别把果汁的中层位置答成底层、把护腰的顶层位置答成中层。训练方式、热身道具和教练职业等回答与金标匹配。bedroom_04 为 7 题满分、4 题零分，均分 0.6364；其中两题超时，另两题是过去偏好的演员答错，以及将 Mia 的薯片偏好答成巧克力。这些例子提示应继续检查空间细节、人物–偏好绑定和时序转换，但不构成已定位到某个具体模块的因果证据。两视频 QA 输入峰值分别为 131,454 和 144,546 tokens，说明长检索上下文现象不只存在于首视频。

7 2026 年 11 月 1 日：study_18 恢复与片段容错

首轮 study_18 的第 52 号片段返回人物/实体片段，而不是完整情景记忆，被校验器拒绝，导致后续索引和 14 题问答未执行。本次在首轮数据库的独立克隆上定向恢复，不覆盖首轮数据库或成绩。

恢复仅新增 1 条记忆，复用的 83 条正文及结构化内容逐项不变，最终完成 84/84 条记忆和索引；14/14 题有效回答，无超时和评委错误。恢复视频参考均分为 **0.3929**。保持原四视频的答案与评分不变，仅补齐该视频后，65 题组合均分为 **0.5538**，有效答案 59/65。这是覆盖恢复，不是对所有题重跑后择优，也不是模型或记忆架构的独立增益；首轮 0.4692 的记录仍完整保留。共同评委下的 M3-Agent 对照属于另一次评分。

oGMemory 的改动已提交到 `m3_dev_1031`：`99b22866` 保存模型推理参数和有界并发，`40ac1dcd` 增加无效输出重试及显式部分覆盖，`c992d45b` 保证连接指纹不包含凭据及其哈希。域无效输出可额外重试一次；若仍有少量失败，只有至少 95% 覆盖、回执与图一致、且没有旧失败节点可能混入时，才允许索引与问答继续。缺失片段进入提示和每题回执；全量完成的续跑判定不会误接受部分证据。鉴权、存储或低覆盖继续失败关闭。

相关扩展测试为 1063 passed、1 deselected；排除的一项音频重建重复节点测试已在修改前源码复现，不属于本次引入。另有独立 SQL 故障注入：强制片段 52 连续失败，剩余 83 条仍实际建索引，测试 QA 继续并披露缺失，最终退出码保持 2。该测试使用 stub 回答，不计入模型成绩。

8 同模型 M3-Agent 适配对照（2026 年 11 月 1 日）

本节保留首次同模型共同评分批次；后续上下文消融的交错重评另列。不同批次不能择高拼接，重评分数变化不等于原答案发生变化。本组从原视频重新计算 M3 感知和记忆，不复用 oGMemory 的情景/语义记忆或数据集预生成图。同一份新 M3 记忆搭配原生工具移植和参考 Action 文本协议两种控制器，分别运行全部 65 题，不择优拼接。两组官方检查点没有部署，因此这是适配实验。本组 oGMemory 的均分比 M3 参考文本协议版高 0.0846。这仅适用于当前五视频和适配设置，不能声称官方 M3-Agent 被全面超越。原生工具诊断版和参考文本版的记忆完全相同，但控制器完成率差别

方法	有效答案	65 题参考均分
oGMemory（恢复后固定答案）	59/65	0.5462
M3-Agent 适配：参考 Action 文本协议	65/65	0.4615
M3-Agent 适配：原生工具移植诊断	28/65	0.2154

视频	oGMemory	M3 参考文本	M3 原生工具
study_05	0.3333	0.5417	0.2083
gym_03	0.7273	0.5909	0.2273
bedroom_04	0.6364	0.5455	0.2727
study_18	0.3571	0.2857	0.0000
kitchen_20	0.6765	0.4118	0.3529

明显；文本版保留末轮允许合理猜测的指令，有答案不等于有充分事实依据。统一评委的两条限流失败仅补评失败项，最终三组评委错误均为零。oGMemory 预测没有修改；共同评分 0.5462 与此前组合评分 0.5538 的差异来自重评波动。所有原始故障和先前评分均保留。65 题的实际时间截止点已逐项核对一致。五视频的采样帧和 WAV 逐文件一致；四视频转写一致，study_18 的 clip 61 有四条转写/时间差异。M3 额外使用身份裁剪，感知后端、控制提示和原版策略存在已记录适配，故不是严格单变量架构实验。服务负载、开发停顿和限流也使总墙钟不可直接作严格加速比。详细三列逐题结果、原函数指纹、输入核对与方法偏离见 `experiments/m3_end_to_end_comparison_20261101/`。

9 上下文预算与 QA 收尾消融（11 月 1 日）

本节保留 11 月 1 日的实验、评分及当时的验证记录；11 月 2 日的追加实验另列，不择高拼接不同批次分数。本节固定已生成的多模态记忆，仅重新运行 QA。旧 oGMemory 和 M3-Agent 为固定的既有答案；A/B/C/D 及 B 的完整重复均保留，未择高。将七组共 455 条答案交错打乱后用相同 MiniMax 评委重新评分，评委不接收方案名称。初次评分仍保留；共同重评批次与前节不同，旧答案本身没有修改。

方案	有效回答	独立评分	共同评分	输入/M	峰值/k	调用
原固定答案	59/65	0.5462	0.5385	19.906	156.69	319
M3 参考协议	65/65	0.4615	0.4615	0.570	4.74	310
A：仅预算	65/65	0.5538	0.5538	4.722	16.90	359
B：预算 + 收尾	65/65	0.6000	0.6077	4.804	16.92	365
C：12k+ 收尾	64/65	0.5231	0.5231	2.722	9.10	366
D：12k 分组 + 收尾	65/65	0.5308	0.5385	2.760	9.25	366
B 独立重复	65/65	0.5615	0.5769	4.708	16.93	361

A 曾遇到套餐额度中断：恢复时保留 55 条成功答案和 48 条成功评分，只补做额度导致的失败与未评分部分。B 的前次尝试没有有效答案，另立目录完整运行。原失败记录和未知 usage 的请求开销均保留，未按题挑选高分。评分为 0、0.5、1 自动评分的全 65 题均值，不是人工准确率。输入包含缓存 tokens，不等于费用；跨时段服务负载不同，不能据此声称严格墙钟加速比。五组新轨迹共 325 条 QA 记录，324 条有效回答，记录到 0 条 QA 超时；单题实际墙钟最大 112.53 秒。这些

是恢复后的固定轨迹，先前额度失败另列。C 的一条协议校验失败保留计零；没有把 done 状态直接当作有效答案。

9.1 逐视频共同评分

视频	原答案	M3 参考	A	B	C	D	B 重复
study_05	0.3333	0.5417	0.5000	0.6250	0.5417	0.2917	0.5000
gym_03	0.7273	0.5455	0.6364	0.7273	0.6818	0.7727	0.6818
bedroom_04	0.6364	0.6364	0.8182	0.8182	0.6364	0.8182	0.8182
study_18	0.3214	0.2500	0.2857	0.3214	0.2500	0.2857	0.2500
kitchen_20	0.6765	0.4118	0.5882	0.6176	0.5588	0.5882	0.6765

9.2 诊断、机制与限制

原 6 道超时题的模型调用累计 183–230 秒，检索仅 1.1–1.7 秒。首轮约 1250 输入 tokens，随后重复的完整片段对象使输入累积至 9 万–12 万。A 复用原仓已有但正式基线未开启的上下文预算模块：内容版本去重、连续原文选择、有效引用和完整请求计数。22528 输入预算预留 8192 输出及 2048 安全空间。新组还统一限制请求 top-k 不超过 16、候选不超过 32、单次总返回节点不超过 24、每题 Search 尝试不超过 8 次；A 因此是整套有界策略，而不只是删除重复字符串。B 增加 45 秒回答预留，并在最后一轮关闭 Search；C 将输入估计上限降为 12000。D 在相同 12000 预算下将已选原文按字段分组，去除重复包装和模型无需读取的内容哈希；原始值、来源范围、人物与时间元数据不改写，完整哈希保留在审计中。计数器使用本地 Qwen tokenizer 代理，不等同于 MiniMax 的精确模板。

A：仅预算相对原答案评分差为 +0.0154，累计输入下降 76.3%，峰值下降 89.2%。按 5 个完整视频簇枚举重采样的 95% 区间为 [-0.0786, +0.1250]。

B：预算 + 收尾相对原答案评分差为 +0.0692，累计输入下降 75.9%，峰值下降 89.2%。按 5 个完整视频簇枚举重采样的 95% 区间为 [-0.0286, +0.2049]。

C：12k+ 收尾相对原答案评分差为-0.0154，累计输入下降 86.3%，峰值下降 94.2%。按 5 个完整视频簇枚举重采样的 95% 区间为 [-0.0921, +0.1066]。

D：12k 分组 + 收尾相对原答案评分差为 +0.0000，累计输入下降 86.1%，峰值下降 94.1%。按 5 个完整视频簇枚举重采样的 95% 区间为 [-0.0625, +0.1000]。

B 独立重复相对原答案评分差为 +0.0385，累计输入下降 76.4%，峰值下降 89.2%。按 5 个完整视频簇枚举重采样的 95% 区间为 [-0.0448, +0.1316]。

5/5 个方案或重复运行的上述区间包含 0。这些仅是五个开发视频的探索性重采样结果，不能据此宣称稳定的统计显著质量增益。

9.3 覆盖恢复与已有答案的取舍

主指标仍使用全 65 题。以下仅将总分变化分解为原 59 道有答案题与原 6 道无答案题的贡献，不改用成功子集均分，也不把这一记账分解当成单一因素的因果证明。

条件	原 59 题分值变化	原 6 题分值变化	净分值变化
A：仅预算	-4.0	+5.0	+1.0
B：预算 + 收尾	-1.5	+6.0	+4.5
C：12k+ 收尾	-6.0	+5.0	-1.0
D：12k 分组 + 收尾	-4.0	+4.0	+0.0
B 独立重复	-2.5	+5.0	+2.5

本批总分进展主要伴随原超时题恢复，原已回答题仍有损失。因此结论是效率与回答覆盖得到改善，但单题事实质量存在取舍，不能声称推理能力普遍提升。

9.4 重复运行与评分波动

B 两次共同评分为 0.6077 与 0.5769，绝对差 0.0308；12 题的自动评分不同。两轮均分的描述性平均为 0.5923，不择高、不拼接答案。同一 65 题的重复不等于 130 个独立新问题，仅两轮不能精确估计随机波动或支持泛化结论。上述区间仅用于呈现小样本不确定性：五个视频均为开发样本，不是独立留出集。未触发时间预留的运行不能证明 45 秒机制带来收益；提前收尾也不能保证单个极慢 HTTP 不会越过软截止。M3-Agent 仍为同模型适配而非官方权重复现。原文被预算省略不等于事实不存在，计数题尤其不能把入选片段数当作真实次数。源帧定性检查还发现：study_18 第 14 片段的输入止于 435 秒远景，445–446 秒出现的货架近景与取纸动作没有进入 16 帧前缀采样。这提示采帧/记忆细节的上游限制，但这些尾段帧在 434 秒问题时间之后，只在本次 current_clip 宽限内，不能用于严格因果评测。辅助检查没有改变任何本轮模型输入或答案。详细结果、逐题变化和验证记录位于`experiments/m3_context_study_20261101/`；设计说明见`docs/m3_context_optimization.md`。

9.5 缓存与未缓存输入

重打包会改变较早的工具消息，可能削弱稳定前缀。实际 usage 显示缓存比例改变，因此总输入降幅不能直接当成费用或套餐额度降幅。缓存内部实现与跨时段服务负载没有被本实验严格控制。相同 12000 预算下，D 最终视图平均保留 78.83 条原文条目/片段，C 为 66.66。这不是独立事实计数；查询轨迹也不同，不能解读为固定查询的信息增益。压缩空间可能用于装入更多原文而非降低 API 输入，是否有助于答案质量仍需看实际评测。本轮所有实际调用日志去除重复文件后共记录 2635 次逻辑调用，45 次 usage 未知；收到输入 20.202M 和输出 0.497M tokens，另有 209-token 可用性探针。此为全部试验开销，与单条件固定轨迹用量不同；不含先前记忆生成与历史基线，也不是账单。强制停止时未落盘的在途请求无法凭现有日志完整计量。

9.6 验证与配置使用

当前发布代码的 M3/provider/core 单元检查 1041 项通过；扩大检查排除 9 项已复现的既有问题后为 1388 通过、108 跳过、9 排除。不能将排除等同于修复，也不能称整个仓库全部通过。各实验使用各自冻结源码，源码文件与 Git 归档逐项核对；共同评分输入和原预测文件在发布前重新校验，而不只信任状态标记。可用`python-mm3.configure_qa_context` 生成新的 0600 配置副本，保留模型与连接设置。它针对 ReAct QA/pipeline，不是旧单次 QA 入口；切换策略必须使用新的输出目录，不应跨配置 resume 旧答案。

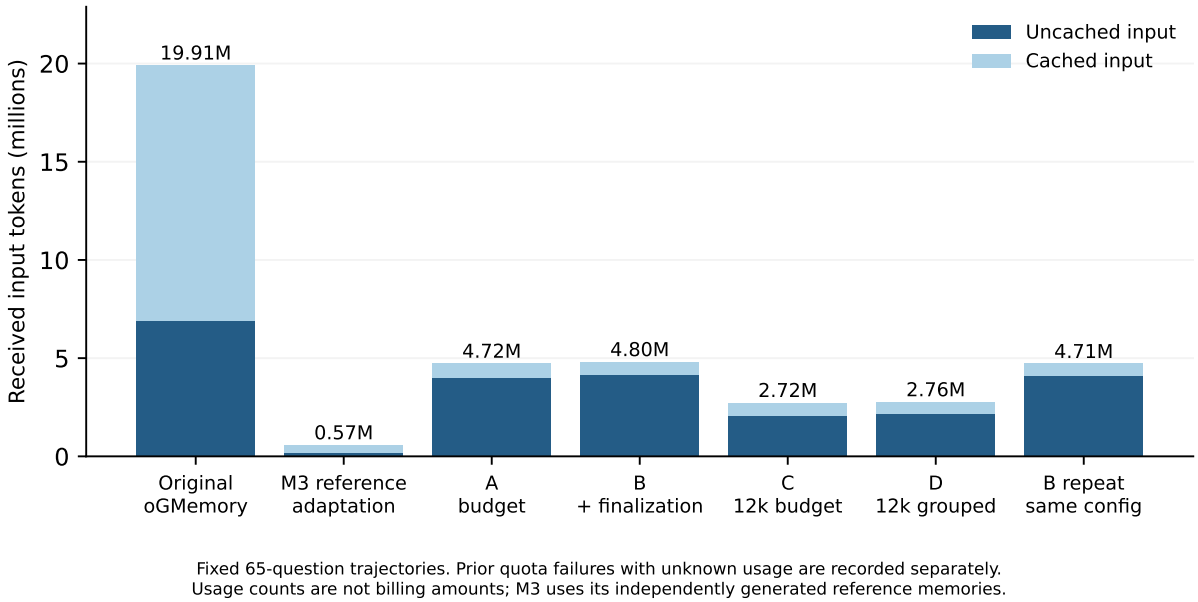


图 1: 固定答案轨迹的实际输入用量。深色为未缓存输入，浅色为缓存输入；未知 usage 的额度失败请求另行保留，不计作零费用。

9.7 本轮建议

质量优先时建议先采用 balanced：输入目标 24000，在 8192 输出和 2048 安全预留下实际输入估计上限为 22528，6 轮/180 秒，并保留终轮 Answer-only 与控制提示。45 秒预留本轮未实际触发，仅能作为经单元验证的保护机制。compact/grouped 保持可选，不因编码更短或原文更多就默认上线。下一阶段应在新视频及严格时间策略下验证前缀更稳定的证据交付、带来源与可用时间的实体事实索引；采帧覆盖、身份归属和事件计数应单独消融，不能通过引入未来帧或事后答案改变本轮成绩。

10 来源事实、人物条件与增量交付（11 月 2 日）

本轮固定原有 340 个片段记忆与 65 题，不重新生成感知或记忆。新增可追溯原文事实窗口、显式人物条件软排序和前缀稳定的增量交付。S 额外使用 GPU BGE-M3 构建的 7965 个事实窗口旁路索引，按账号/视频/时间筛选并回源核对内容哈希；同时改为按实际新增可见事实判断停搜。人物条件不等价于已核实的人脸/声音身份解析。

方案	有效回答	共同评分	QA 输入 token	调用
B：前次 balanced	65/65	0.5923	4,804,362	365
B：前次独立重复	65/65	0.6000	4,707,523	361
M3-Agent 同模型参考适配	65/65	0.4615	569,796	310
F：原文事实窗口	65/65	0.5000	2,560,063	366
FI：事实 + 显式人物条件	65/65	0.4923	2,548,205	365
FIP：事实 + 人物 + 增量	64/65	0.5462	3,314,963	366
S：来源事实索引 + 增量修正	65/65	0.5846	3,456,572	369
S：独立重复	65/65	0.6077	3,408,547	365
B：本轮同期独立重复	65/65	0.5308	4,721,119	361
M3-Agent：本轮同记忆重复	65/65	0.4615	551,699	302
E：严格增量 3500 + 收尾请求	65/65	0.5846	2,915,704	370

同批评委共 715 条固定答案，seed=1102 随机交错，不向评委发送方案名。S 独立运行两次的描述性均值为 0.5962，同期 B 为 0.5308。这些是小规模开发集自动评分，不是人工准确率或官方 M3-Agent 复现。全部消融、失败、逐题评分与用量见`experiments/m3_memory_design_20261102/REPORT.md`。索引构建约 63 秒、37MB，QA 用量不包含历史记忆生成。输入含缓存，不能将输入 token 比例当成费用或端到端加速比。 实现及安全边界见`docs/m3_memory_design.md`。

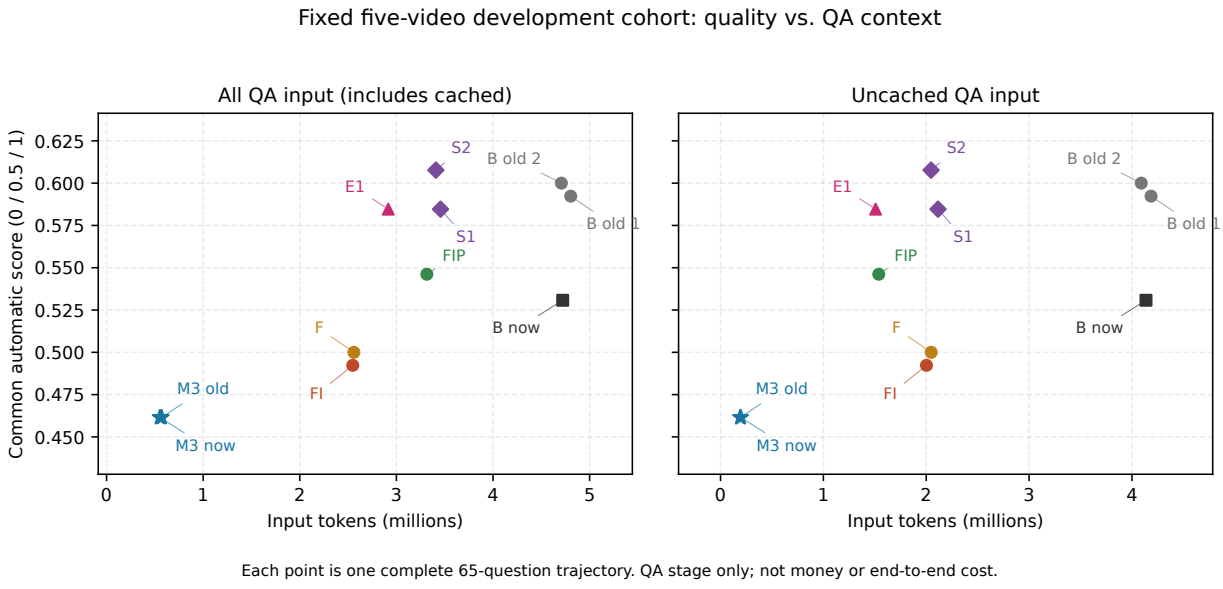


图 2: 同批自动评分与 QA 输入。每点为完整 65 题轨迹，重复运行分别显示；不是费用或端到端开销。

10.1 五视频结果

S 为两次轨迹的分视频平均，M3 为原轨迹与本轮重复的平均；重复不增加独立题数。

视频	题数	B 同期	S 均值	E	M3 均值
study_05	12	0.4167	0.4583	0.4583	0.4583
gym_03	11	0.6818	0.6591	0.6364	0.6364
bedroom_04	11	0.7273	0.7955	0.7727	0.6364
study_18	14	0.3214	0.4286	0.4643	0.2679
kitchen_20	17	0.5588	0.6618	0.6176	0.3971

例如 E 在 gym_03 低于同期 B，不能宣称每个视频都提升；study_18 仍是短板。

10.2 按数据集类别的诊断

类别为数据集多标签，同一道题可属于多个类别，不能相加当作总分。多跳推理只有 1 题，不作能力泛化判断。以下仍是同批自动评分。

方案	人物理解 (21)	跨模态推理 (21)	多细节推理 (28)	知识提取 (25)	多跳推理 (1)
M3 同期重复	0.643	0.452	0.393	0.440	0.500
B 同期	0.833	0.548	0.429	0.420	1.000
S 首次	0.857	0.667	0.518	0.460	1.000
S 重复	0.881	0.643	0.464	0.600	1.000
E 首次	0.881	0.571	0.518	0.480	0.500

10.3 结论：输入效率改善，稳定提分仍需验证

S 两次共同评分为 0.5846 与 0.6077，均值 0.5962，恰好等于前次两条 balanced 固定答案在本批评委下的均值。同期新 B 为 0.5308，显示对照自身也有明显运行波动。因此不能只选 S 较高的一次或只比较较低的同期 B，就宣称稳定全面提分。前次原评分仍保留；本节使用的是新共同评委重评，不是改写旧答案。

E 为 0.5846，65 题均有有效回答，但尚无独立重复；其重复因额度 16% 低于预设启动门槛而未执行，并非因分数低而取消。E 较同期 B 的 QA 总输入减少 38.2%，未缓存输入减少 63.6%；较 S 两次平均分别再减少 15.1% 和 27.5%。更稳妥的定位是**保持此前质量附近的低输入候选**，而不是已经证实的无损压缩或稳定准确率提升。建议保留 balanced 作回归基线，在新额度窗口先完成 E 重复。

10.4 三条改进路线的实际边界

仅原文事实窗口 F 为 0.5000，说明切短本身不保证效果。S 增加了来源事实向量索引等组合变化；其 371 次实际查询离线重放全部复现原入选集合，355 次在关闭索引后主片段选择改变，19 次选入原候选池之外的节点。因此多数变化是重排与细粒度准入，不应写成大幅扩大正确证据召回。重放未使用 gold，只说明检索路径，不证明提分因果。

FI 相对 F 总分差为 −0.0077，探索性区间跨零。其人物理解类别有所改善，但知识提取下降；类别重叠，不能挑有利子集代表整体。当前 name/role 匹配仍是来源声明，不是人脸、声音和姓名的核实绑定。部分错例已经看到了正确词，却把偏好或物品归给了错误对象；解决这种错误需要可信的实体–事实关系，而非更强的名字共现过滤。

首版增量计数会把不发送给模型的审计字段算入基数：1000 代理单位反例可准入 7095，修复后有无该字段均只增加 890。**修复前总输入上限仍有效**，这是新增额度失真，而非旧实验输入越界。E 改为实际模型投影计数和 3500 步长，370 次 QA 调用没有 epoch 重建；305 次相邻消息前缀全部保持，实际最大新增量 3500。消息前缀检查不包含工具 schema，也不等价于供应商缓存保证。

57 次请求设置 required 且仅提供 Answer，其中 41 次返回原生 Answer，16 次仍返回普通文本，由既有有效文本兼容路径接受，没有追加调用。不能把该参数描述成严格原生输出保证。45 秒回答预留本轮也未触发。此外，32 节点/每节点 12 条约束的是本次新增准入，不是整个增量历史；E 最多可见 38 个节点，全局仍以总输入预算约束。

10.5 与 M3-Agent 的取舍

M3 参考适配两次轨迹在本批评委下均为 0.4615，逐题答案并不相同。S 均值高 0.1346，E 高 0.1231，但 E 的 QA 输入仍为 M3 两次平均的 5.20 倍，未缓存输入约 7.77 倍。M3 的紧凑事件/语义事实、身份条件检索与少量新片段交付仍有明显效率优势，不能从本批得分推出我们的身份图推理更强。两者控制协议和末轮猜测策略不同，且参考方是同模型适配，不是官方 checkpoint 复现。

10.6 审计结果与用量采集缺口

七个新 oGMemory 轨迹共 455 题，454 个有效回答，唯一失败为 FIP 的 Search 文本协议；M3 同期重复 65 题均有效。251,023 个实际可见原文位置经还原验证，数据库内容与事实索引 hash 不变。来源一致不保证源记忆和最终答案真实正确。本轮未重新生成 AV 感知，仍受前缀帧采样、ASR 与人物归属问题影响；current_clip 允许看至当前片段末尾，非严格因果在线评测。

共同评委用量日志存在缺口：715 条评分已完成且无评委错误，但 Python 启动时 sitecustomize 因源码路径缺失，未成功安装用量采集。714 个需要模型评分的任务没有持久化 usage 或逐响应模型标识；已结束进程的内存计数无法恢复。配置与冻结代码仍可核查。没有重评成功项或用估计值补账。全部 QA 轨迹用量完整，故 QA 输入比较仍有效，但不能给出整轮实验的完整总 token 或费用。已修复后续启动环境并增加采集未就绪即禁止模型调用的回归检查。

工程验证包括 1447 项扩展检查通过、108 项跳过及 9 项此前已复现的既有失败排除；根仓评测与审计工具 79 项测试通过。排除并不意味着旧失败已修复。新增索引构建入口使用只读事务和租户/视频过滤，真实数据 dry-run 及原向量写入回放通过，未覆盖本轮固定索引。

本研究仅 5 个开发视频、65 题、同模型自动评委。聚类重采样区间只刻画固定答案上的视频波动，不能覆盖所有生成与评委随机性，亦非多重开发比较后的确认性检验。详细证据与未运行组状态见 `docs/m3_memory_design_findings.md` 和 `experiments/m3_memory_design_20261102/`。

11 改进方向与后续对照设计

1. **运行可靠性：**启动前校验在线模型名、数据库扩展和多模态完整输入；统计记忆截断、QA 上下文超限与评委异常，分别处理而非笼统归为低准确率。

2. **视觉覆盖：**固定 16 帧预算，对比前缀采样与整片段等距采样，再讨论动作自适应采样，避免同时改变帧数和采样位置而无法归因。

3. **有界上下文：**固定记忆的预算、控制与增量交付已开展验证；下一步先完成严格增量方案的独立重复，再研究完整请求（含工具 schema）的前缀稳定性，同时报告缓存、质量、请求大小、调用次数和失败率，而不只报告 token 缩减。

4. **事实和时序：**为对象位置、材料、人物归属保存可定位证据；区分计划、建议与已完成事件；计数使用可去重事件时间轴而非检索条数。

5. **图结构价值：**明确语义节点与身份边何时进入检索，设计情景记忆、加入身份关联、加入分层语义摘要的逐项消融。

6. **评测可信度：**固定独立评委并人工抽查零分、半分和计数/空间问题，将本轮样本作为开发集，另设未调参的新视频集验证泛化。

以上未在结果节明确记录为已完成的部分属于后续建议；不能表述为本次已实现或已验证的算法增益。

12 复现与产物

先在交互式 bash 中 source 用户的 `~/.bashrc` 并导出 `MINIMAX_API_KEY`，原完整视频基线可在 memory-eval 根目录执行 `bashscripts/run_m3_flash_medium.sh`；私有配置路径由脚本固定，提交版仅保留脱敏配置和配置哈希。实验完整媒体、原始模型输出与运行日志位于 `runs/`，默认不入 Git。轻量结果位于 `experiments/m3_flash_medium_20261031/`，包括抽样 manifest、输入清单、版本记录、逐题 CSV/JSONL、机器统计与测试日志。具体恢复步骤和结果状态以同目录报告为准。

统计脚本 `scripts/summarize_m3.py` 校验标注哈希、固定题数、重复答案、样本外记录以及评分与预测的一致性。它不会悄悄从多轮尝试里选择最高分。首轮兼容修改后实际执行 M3、LLM provider 与管线集成测试：976 passed；外层统计脚本另有 9 项测试通过。后续 QA-only 消融使用 `scripts/run_context_experiment.py` 冻结源码和配置，从指定原数据库读取记忆，不应为改变 QA 控制器而重新运行全视频抽取。其恢复规则、实际提交和测试边界记录于 `experiments/m3_context_study_20261101/PLAN.md` 与 `VALIDATION.md`。当前代码提供 `python -mm3.configure_qa_context`，将选定上下文方案写入新的 0600 私有配置副本，保留模型与连接设置，不调用服务。切换策略时必须使用新的 QA 结果文件/实验目录，不能对旧答案直接 resume；配置工具也不能用于改写已冻结实验。具体参数见 `oGMemory/docs/m3_bounded_context.md`。LaTeX 使用 `ctexart` 与 XeLaTeX，在工作区根目录执行 `bashscripts/build_report.sh`，或进入本目录执行 `make`。脚本检查中文依赖，用 latexmk 自动完成交叉引用收敛，只在成功时发布 `latex/report.pdf`；构建日志与输入哈希保存在 `latex/build/`。

参考文献

[1] oGMemory dev，固定提交 `8c86c3ed`。主要实现：`m3/pipeline/`、`m3/episodic_memory.py`、`m3/control_adapter.py`、`m3/index_episodic.py`、`m3/temporal.py`、`m3/eval.py`。

[2] 本地实验协议：`docs/m3_random_subset.md`、`docs/m3_bounded_context.md`、`docs/m3_semantic_consolidation.md`。历史文档的成绩未用作本次实测结果。

[3] 本地 M3-Bench 数据副本：`/data/m3_data/`，robot 标注版本哈希见 `sample_manifest.json`。

[4] 本地 M3-Agent 参考仓库，提交 `0e3e419`；`m3_agent/control.py`、`mmagent/retrieve.py`、`mmagent/videograph.py` 与 `mmagent/memory_processing_qwen.py`。本节为参考代码分析；后续同模型适配评测不等同于官方权重复现或论文成绩。